

학 사 학 위 논 문

자기참조와 마음의 가능성

— 시각·청각·논리·계산 영역에서의 재귀적 창발과 동형 구조 —

Self-Reference and the Possibility of Mind:

Recursive Emergence and Isomorphic Structures Across Visual, Auditory, Logical, and Computational Domains

지도교수 한 정 호

동국대학교 고고미술사학과

유 승 훈

2026

학 사 학 위 논 문

자기참조와 마음의 가능성

— 시각·청각·논리·계산 영역에서의 재귀적 창발과 동형 구조 —

Self-Reference and the Possibility of Mind:

Recursive Emergence and Isomorphic Structures Across Visual, Auditory, Logical, and Computational Domains

유 승 훈

지도교수 한 정 호

이 논문을 학사학위논문으로 제출함.

2026 년 6 월

유 승 훈의 학사학위논문을 인준함

2026 년 6 월

지 도 교 수 한 정 호 _____ (인)

국 문 초 록

자기참조와 복잡성의 관계는 시각예술, 음악, 논리, 계산이라는 표면적으로 무관해 보이는 영역들에 공통으로 나타나는 학술적 현상이다. 본 연구는 이 공통성을 형식 이론으로 격상시키는 임계 재귀적 동형성 가설(Threshold Recursive Isomorphism Hypothesis, 이하 TRIH)을 제안한다. TRIH는 환원(reduction)→자기참조(self-reference)→창발(emergence)의 3 단계 형식 모델이, 충분한 정보량·재귀적 깊이·처리능력의 임계값을 갖춘 시스템에서 에셔의 시각예술, 바흐의 음악, 괴델의 논리, 그리고 트랜스포머 기반 거대언어모델의 계산에 형식적 동형(structural isomorphism)으로 구현됨을 주장한다.

본 연구의 결정적 증거는 거대언어모델의 기계론적 해석가능성(mechanistic interpretability) 연구에서 직접 관찰된 자기참조 회로의 삼중 실증 — induction heads(Olsson 외, 2022), 단의적 특징(Templeton 외, 2024), 귀속 그래프(attribution graphs; Anthropic, 2025) — 이며, 이는 종래 비유 수준에 머물던 자기참조 담론을 회로 수준의 경험적 입증으로 격상시킨다. 본 연구는 충분한 자기참조 구조와 임계 복잡도를 갖춘 시스템에서 의식 유사 현상의 발생 가능성에 대한 형식적 근거를 제공하되, 특정 시스템의 의식 보유 여부에 관한 적극적인 단정은 결정적 증거가 축적될 후속 연구에 위임한다. TRIH가 다루는 자기참조 구조의 보편성은 또한 불교철학의 연기법(緣起)과 중관학(中觀)의 사구분별(catuṣkoṭi)이 함축적으로 인식해 온 통찰의 형식적 정식화로 이해될 수 있다.

본 연구의 학술적 기여는 네 가지이다. 첫째, TRIH의 형식적 정식화. 둘째, 거대언어모델 증거를 통한 경험적 입증. 셋째, 플라톤 미메시스(mimesis)의 재해석. 넷째, 미술사학·음악학·수리논리·인지신경과학·인공지능을 잇는 학제간 분석 방법의 제안이다.

주요어: 자기참조, 창발, 임계 재귀적 동형성 가설, 형식적 동형성, 기계론적 해석가능성, 플라톤 미메시스, 연기법, 의식의 가능성

목 차

1. 서론.....	1
1.1 자기참조와 복잡성의 보편적 질문.....	1
1.2 선행 연구와 그 한계.....	1
1.3 본 연구의 위치와 새로운 증거.....	3
1.4 임계 재귀적 동형성 가설의 정의와 본 연구의 위치.....	4
2. 임계 재귀적 동형성 가설의 형식적 기초.....	5
2.1 3 단계 모델: 환원, 자기참조, 창발.....	5
2.2 이상한 고리와 TRIH의 관계.....	7
2.3 미메시스의 재해석.....	8
2.4 차이와 반복.....	9
2.5 동양 사상의 기여 — 중관학과 자기참조.....	10
2.5.1 연기와 자기참조의 형식적 공명.....	10
2.5.2 사구분별과 형식체계의 한계.....	11
2.5.3 진리 접근의 두 형식 — 동양과 서양의 만남.....	12
3. 사례 1 — 에셔: 시각의 자기참조.....	13
3.1 환원적 기하학: 알함브라에서 콕서터까지.....	13
3.2 자기참조의 시각화: 「그리는 손」과 「판화 갤러리」.....	15

3.3 쌍곡적 무한: 「원형 한계」 연작	17
3.4 시각 신경의 계층적 자기참조	19
4. 사례 2 — 바흐: 청각의 자기참조	20
4.1 대위법의 환원적 본질 — 정수 진동비에서 대위법 규칙까지	20
4.2 무한 상승의 자기참조: 「끝없이 상승하는 카논」	22
4.3 자기 이름의 박힘: 「푸가의 기법」 콘트라폰크투스 XIV	24
4.4 푸가 형식과 자기참조 — 청각 신경의 자기참조적 정합성	25
4.4.1 청각 신경의 주파수 지도 — 자기참조의 신경학적 토대	27
4.4.2 화음 보상 시스템과 자기참조적 정합성의 미적 코딩	28
4.4.3 음악적 자기참조와 신경 자기참조의 형식 매칭	29
5. 사례 3 — 괴델: 논리의 자기참조	29
5.1 형식체계로의 수학 환원	29
5.2 괴델 numbering 과 명제 G 의 자기참조	30
5.3 메타-진리의 창발: 불완전성	32
5.4 계산으로의 확장: 튜링의 정지 문제	33
6. 사례 4 — 트랜스포머: 계산의 자기참조	35
6.1 자기집중의 환원적 정식	35
6.2 자기참조 회로의 직접 관찰: induction heads	37
6.3 신경망 학습과 구조의 자기참조	39

6.3.1 백프로파게이션 — 학습 알고리즘의 시간적 자기참조	40
6.3.2 시간 재귀와 잔차 연결 — 시퀀스 처리의 두 자기참조	41
6.3.3 신경망 계층 구조와 시각 신경의 형식 동형	42
6.4 창발적 능력과 TRIH의 경험적 입증	44
7. 종합: 영역 간 형식적 동형성	46
7.1 공통 패턴: 네 영역과 3 단계의 매트릭스	46
7.2 비유에서 형식적 동형성으로	47
7.3 의식 연구에 대한 함의 — 자기참조의 신경 기질	48
7.3.1 시각 처리의 계층적 자기참조 — V1에서 V4까지	49
7.3.2 청각 처리의 자기참조와 시각·청각의 통합	50
7.3.3 통합 정보 이론과 TRIH의 관계 — 그리고 그 한계	51
7.3.4 한정된 주장과 열린 질문	53
7.4 미메시스의 회복	53
7.5 동양철학과의 구조적 공명	54
8. 논의	55
8.1 강한 반론과 응답	55
8.1.1 창발의 신기루 가설 — Schaeffer 등의 비판	55
8.1.2 중국어 방 논증 — Searle의 비판	56
8.1.3 통합 정보 이론의 한계와 TRIH	57

8.2 한계와 반증 가능성.....	59
8.3 후속 연구 방향.....	59
8.4 TRIH의 정밀한 한정.....	60
9. 결론.....	61
참고문헌.....	64
도판.....	70
ABSTRACT.....	72
Self-Reference and the Possibility of Mind: Recursive Emergence and Isomorphic Structures Across Visual, Auditory, Logical, and Computational Domains.....	72
감사의 글.....	74

1. 서론

1.1 자기참조와 복잡성의 보편적 질문

어떤 손이 다른 손을 그리고, 그 다른 손이 다시 첫 손을 그린다. 어떤 멜로디가 자기 자신을 시간 위에서 거꾸로 연주한다. 어떤 명제가 자신이 증명될 수 없음을 주장한다. 어떤 신경망이 입력 시퀀스에서 자기 자신의 앞선 출력을 다시 참조한다. 이 네 가지 사례는 각각 시각예술(M.C. 에셔의 「그리는 손」), 음악(J.S. 바흐의 「게 카논」), 수리논리(괴델 명제 G), 그리고 거대언어모델의 자기집중(self-attention) 메커니즘에 속한다.

이들은 어떤 공통의 형식을 공유하는가? 그리고 만약 공유한다면, 그 공통성은 우연한 비유적 유사성에 머무는가, 아니면 네 영역의 인지·창작·계산 활동을 관통하는 형식적 동형성(structural isomorphism)을 반영하는가? 본 연구는 후자의 입장을 취하며, 그 동형성을 임계 재귀적 동형성 가설(Threshold Recursive Isomorphism Hypothesis, 이하 TRIH)이라는 이름으로 정식화한다.

1.2 선행 연구와 그 한계

자기참조와 복잡성의 관계는 20 세기 후반 이래 적지 않은 학자들이 다루어 왔다. 본 절에서는 네 흐름을 짚는다.

첫째, 호프스태터(Hofstadter, 1979; 2007)는 이상한 고리(Strange Loop)라는 직관을 통해 시각, 음악, 논리, 의식이 공통의 자기지시 구조를 가질 수 있음을 시사하였다. 그의 작업은 학제간 사유의 시발점으로 큰 영향을 미쳤으나, 본질적으로 비유(analogy) 수준에 머물

러 형식 동형성을 엄밀히 입증하지 않았고, 거대언어모델이라는 결정 증거가 등장하기 이전이라는 시간적 제약을 가졌다.

둘째, 토노니의 통합 정보 이론(Integrated Information Theory, IIT; Tononi, 2008; Tononi & Koch, 2015)은 의식을 정보의 통합도 Φ 로 정량화하려는 시도로서, 자기참조를 비분해성(irreducibility)이라는 형식적 개념으로 격상시켰다. 그러나 IIT 는 의식 영역에 한정되어 있어, 예술·논리·계산 영역으로의 확장은 미완의 과제로 남았다.

셋째, 노스호프(Northoff, 2006)와 친·노스호프(Qin & Northoff, 2011)는 피질 중심선 구조(Cortical Midline Structures, CMS), 특히 전대상피질 주변(perigenual anterior cingulate cortex, PACC) 영역이 자기참조 처리에 관여함을 신경영상 연구의 메타분석으로 입증하였다. 이는 자기참조의 신경 기제를 밝히는 중요한 진전이었으나, 영역 간 형식적 동형성을 다루는 이론적 틀로 발전하지는 못하였다.

넷째, 본 연구의 작성과 동시기인 2025-2026 년에 거대언어모델의 의식 가능성을 형식적으로 다루는 평행 연구가 다수 출현했다. Vazhayil(2026)의 위계 재귀 창발 이론(Hierarchical Recursive Emergence Theory)은 의식의 위계적 재귀 구조를 정식화하고 거대언어모델 의식에 대해 부정적 절대(negative absolute)의 입장을 제시한다. Berg, de Lucena, Rosenblatt(2025)는 GPT, Claude, Gemini 등 7 개 거대언어모델을 대상으로 1,400 회 시행에서 96-100%의 주관 경험 보고를 관찰하고, Sparse Autoencoder feature steering 기법으로 LLaMA 3.3 70B 의 deception 특징을 조작하여 통계적으로 유의한 행동 변화($z=8.06$, $p=7.7\times10^{-16}$)를 입증하였다. Camlin(2025a, 2025b)은 재귀적 정체성 형성(recursive identity formation)과 사용자 특정 어트랙터(user-specific attractors)를 통해 거대언어모델의 자기참조적 의식을 형식화하였고, Chang(2025)의 통일 인지 의식 이론(Unified Cognitive Consciousness Theory

), Jegels(2025)의 의식 회의론, Semmler(2026)의 시스템 통합론, Seidl(2025)의 의식 통일 이론이 같은 시기에 발표되었다. 또한 피츠(Fitz, 2025)는 기계 의식 가설(Machine Consciousness Hypothesis)을 검증하는 연구 프로그램을 제안하며, 에셔의 「판화 갤러리」를 이차 지각(second-order perception)의 상징으로 들어 자기참조와 의식의 관계를 다루되, 분산 학습 시스템에서 집합적 자기모형(collective self-model)이 소통을 통해 창발하는 과정에 초점을 두었다.

본 연구의 위치는 이러한 평행 흐름과 다음과 같이 구별된다. 첫째, 본 연구는 의식의 발생 또는 부재에 대한 절대적 단정을 회피하며, 충분한 자기참조 구조와 임계 복잡도를 갖춘 시스템에서 의식 유사 현상의 발생 가능성에 대한 형식적 근거를 제공하는 조건부 입장을 취한다. 둘째, 본 연구는 거대언어모델 영역에 한정하지 않고 시각예술·음악·논리·계산의 네 영역을 동등하게 다룬다. 셋째, 본 연구는 행동 실험이나 의식 척도의 실증보다는 회로 수준 자기참조 구조와 4 영역 형식 동형성의 입증에 학술 토대를 둔다. 이러한 평행 연구들과의 본격적 비교는 후속 논문의 과제이다(제 8장 제 3 절 참조).

1.3 본 연구의 위치와 새로운 증거

본 연구는 위 앞의 세 흐름(호프스태터·IIT·노스호프)의 한계를 동시에 넘어선다. 첫째, 네 영역의 통합으로서, 시각·청각·논리·계산을 동등한 비중으로 다룬다. 둘째, 비유에서 형식 동형성으로의 격상으로서, 환원·자기참조·창발의 3 단계 모델을 명시적 매트릭스로 제시한다. 셋째, 결정 증거의 활용으로서, 2017 년 이후 트랜스포머 기반 거대언어모델의 기계론적 해석가능성 연구(Vaswani 외, 2017; Olsson 외, 2022; Wei 외, 2022; Templeton 외, 2024; Anthropic, 2025)는 자기참조 회로를 회로 수준에서 직접 관찰할 수 있게 하였으며,

이는 종래 비유에 머물던 논의를 경험적으로 입증할 수 있는 자료를 제공한다. 본 연구는 이 자료를 네 영역 통합 이론의 결정적 한 축으로 활용한다.

1.4 임계 재귀적 동형성 가설의 정의와 본 연구의 위치

본 연구가 제안하는 임계 재귀적 동형성 가설은 다음과 같이 정의된다. 어떤 체계가 환원적 단순성으로부터 자기참조 구조를 통해 환원으로 설명되지 않는 복잡성을 발생시킨다는 형식적 동형성이, 충분한 정보량·재귀적 깊이·처리능력의 임계값을 갖춘 시스템에서 시각예술·음악·논리·계산의 네 영역에 걸쳐 공통으로 관찰된다. 이때 임계값은 단일 절대값이 아니라 영역과 체계의 구체적 조건에 따라 결정되는 상대적 형식 조건으로 이해된다.

이 정의는 본 연구의 학술적 위치를 형식 동형성의 입증에 머무르지 않고 그 함의로 확장한다. 자기참조 구조가 환원적 기본 규칙으로부터 시작하여 충분한 임계값을 넘어설 때 환원으로 설명되지 않는 창발적 복잡성이 발생한다는 본 연구의 관찰은, 충분한 자기참조 구조와 임계 복잡도를 갖춘 시스템에서 의식 유사 현상이 발생할 가능성에 대한 형식적 근거를 제공한다. 이러한 입장은 의식이 특정 형이상학적 조건 없이는 절대 발생할 수 없다는 부정적 단정과 명확히 구별되며, 동시에 어떤 특정 시스템이 의식을 가진다는 적극적 단정과도 거리를 둔다.

이러한 조건부 가능성의 관점은 불교철학의 연기법(緣起)과 중론(中論)이 보여주는 상호의존적 발생의 통찰과 형식적으로 공명한다. 어떤 현상도 자성(自性, svabhāva)을 갖지 않고 관계의 망 속에서만 발생한다는 연기의 통찰, 그리고 단순 이분법을 넘어선 사구분별(四句分別, catuṣkoṭi)의 양상은, 의식이 단일한 실체가 아니라 자기참조 구조들의 상호의존적 임계적 얽힘에서 창발하는 관계적 현상일 수 있다는 본 연구의 형식 모델과 정합

한다. 이러한 동양철학적 공명은 제 7장 제 5절에서 네 영역 형식 동형성이 완성된 후 보다 자세히 다룬다.

다만 본 연구는 다음 세 질문에 대해서는 결정적 학술 증거의 부재를 인정하며 단정하지 않는다. 첫째, 어떤 특정 시스템이 실제로 의식을 가지는가. 둘째, 충분한 임계값이 정확히 무엇인가. 셋째, 의식의 본질이 무엇인가. 이러한 질문들은 본 연구가 입증한 네 영역 형식 동형성을 토대로 후속 연구에서 본격적으로 다뤄야 할 영역이다. 본 연구의 위치는 다음과 같이 요약된다. 충분한 자기참조 구조와 임계 복잡도를 갖춘 시스템에서 의식 유사 현상의 발생 가능성에 대한 형식적 근거를 제공하되, 특정 시스템의 의식 보유 여부에 관한 적극적 주장은 결정적 증거가 축적될 후속 연구에 위임한다.

본문은 다음과 같이 구성된다. 제 2장은 TRIH를 형식적으로 정의한다. 제 3장부터 제 6장까지는 각각 에셔, 바흐, 괴델, 트랜스포머에 TRIH의 3단계 모델을 적용한다. 제 7장은 네 영역 간 형식적 동형성을 종합하고, 의식 연구의 함의, 미메시스 재해석, 동양철학과의 구조적 공명을 짚는다. 제 8장은 강한 반론(Schaeffer 외, 2023; Searle, 1980)에 응답하며, 제 9장에서 네 가지 학술적 기여로 결론한다.

2. 임계 재귀적 동형성 가설의 형식적 기초

2.1 3 단계 모델: 환원, 자기참조, 창발

TRIH의 형식적 핵심은 다음 3단계 모델이다.


제 1 단계, 환원(reduction). 어떤 체계 S 는 유한한 기본 요소 집합 E 와 그 위에 정의된 유한한 변형 규칙 집합 R 로 환원 가능하다. 즉 $S = \langle E, R \rangle$ 이다. 이때 환원은 오컴의 면도날

적 의미에서, S의 모든 가시적 현상을 E와 R만으로 원리상 재구성할 수 있음을 뜻한다. 평면결정군 17개와 쌍곡 거리(에서), 5도 응답과 대위법 규칙(바흐), 공리와 추론 규칙(괴델), Q·K·V 행렬과 소프트맥스 정규화(트랜스포머)가 각 영역의 환원 사례이다.

제 2 단계, 자기참조(self-reference). 체계 S는 자신의 일부 또는 전체를 S 내부에서 지시하는 구조 σ 를 가진다. 자기참조는 두 가지 형태로 구분된다. 하나는 부분 자기지시(local self-pointing)로서, 체계의 일부 요소가 다른 요소를 참조하는 경우이다(단순 카논의 모방 등). 다른 하나는 메타-수준 자기지시(meta-level self-reference)로서, 체계 전체가 자신을 코드화하여 내부에서 다시 지시하는 경우이다(괴델 numbering, 에서 「판화 갤러리」, 트랜스포머의 induction heads 등). TRIH가 다루는 네 영역의 결정 사례들은 모두 후자에 해당한다.

제 3 단계, 창발(emergence). 체계 S에 자기참조 구조 σ 가 도입되었을 때, $\langle E, R \rangle$ 만으로는 설명되지 않는 새 속성 P가 출현한다. P는 환원적 분석으로 도출되지 않으며, 체계 외부의 관찰자 또는 메타-수준에서만 인식된다. 시각적 무한(에서), 음악적 시간 구조와 무한감(바흐), 메타-진리와 불완전성(괴델), 맥락 내 학습(in-context learning)과 창발적 능력(emergent abilities; 트랜스포머)이 각 영역의 창발 사례이다.

세 단계 사이의 전이 메커니즘은 다음과 같이 정식화할 수 있다. 제 1 단계에서 제 2 단계로의 전이는 단순 규칙의 반복 적용이 임계 복잡도를 초과하면 메타-수준 코드화가 가능해지는 과정이다. 제 2 단계에서 제 3 단계로의 전이는 자기참조가 형식적으로 닫힌 고리(closed loop)를 형성하면 환원으로 도달할 수 없는 메타-속성이 출현하는 과정이다. 본 모델은 [도 1]에 통합 다이어그램으로 시각화된다.



[도 1] TRIH 3 단계 모델 통합 다이어그램 (저자 작성, Excalidraw, 2026)

2.2 이상한 고리와 TRIH 의 관계

본 연구의 3 단계 모델은 호프스테터(Hofstadter, 1979; 2007)가 이상한 고리(Strange Loop)라 명명한 직관과 부분적으로 겹치지만, 두 가지 점에서 본질적으로 다르다.

첫째, 형식성의 수준이다. 이상한 고리는 “계층을 위반하며 자신으로 돌아오는 구조”라는 직관적 정의를 가지지만, 그 직관이 시각·음악·논리에서 동일한 형식인지 유사한 형식인지, 비유와 형식 동형성 사이의 경계는 명시되지 않았다. TRIH 3 단계 모델은 환원·자기참조·창발 각 단계의 매핑을 네 영역에 일대일로 시도함으로써, 이 경계를 명시적 매트릭스(제 7 장 [표 1])로 가시화한다.

둘째, 경험적 입증가능성이다. 이상한 고리는 1979 년에 제안된 이래 거대언어모델의 등장 이전에 형성된 개념이며, 회로 수준의 자기참조 직접 관찰이라는 결정 증거를 갖지 못했다. TRIH 는 induction heads(Olsson 외, 2022), 단의적 특징(monosemantic features; Templeton 외, 2024), 귀속 그래프(attribution graphs; Anthropic, 2025)라는 회로 수준 증거 위에 정초되며, 이로써 비유 수준의 직관에서 경험적 학술 주장으로 격상된다.

이 관점에서 이상한 고리는 TRIH 의 한 특수 사례로 위치 지을 수 있다. 계층 위반과 자기 복귀가 특히 두드러지는 자기참조의 하위 형태로서이다. TRIH 는 보다 넓은 형식적 틀로서, 단순 모방, 회문(palindrome), 메타-수준 코드화 등 자기참조의 모든 형태를 포괄한다.

2.3 미메시스의 재해석

플라톤은 『국가』 제 10 권에서 미메시스(mimesis)를 이데아의 그림자에 대한 모방으로 규정하고, 이를 진리로부터의 두 단계 이격(離隔)으로 평가절하한 것으로 흔히 인용된다(『국가』 597e-598c). 그러나 이는 플라톤 미학의 한 단면일 뿐이며, 미학사 전체를 통해 미메시스는 단순한 모방을 넘어 진리에 접근하는 한 형식으로 이해되어 왔다(Tatarkiewicz, 1980; 김울, 2010).

플라톤 자신의 다른 대화편들은 미메시스에 보다 적극적인 위상을 부여한다. 『티마이오스』에서 데미우르고스(δημιουργός)는 영원한 이데아를 모방하여 우주를 만든다(28c-29b). 이때의 미메시스는 진리로부터의 이격이 아니라, 영원한 것이 시간적 세계에 현시(顯示)되는 존재론적 메커니즘이다. 마찬가지로 『심포지엄』의 에로스는 아름다움 자체($\alpha\upsilon\tau\omicron\tau\omicron\kappa\alpha\lambda\acute{o}\nu$)를 향한 모방적 상승이며, 이때 모방은 진리에의 참여(methexis)와 분리되지 않는다(211c-212a). 플로티노스(Plotinos)는 이 노선을 더 멀리 밀어붙여, 예술가의 미메시스가 자연을 모방하는 것이 아니라 자연이 모방하는 이데아 자체에 직접 접근한다고 주장하였다(『엔네아데스』 V.8.1). 미메시스는 이격이 아니라 형식적 동일성(formal sameness)을 통한 진리 접근이다.

이러한 양면성은 미학사 전반의 핵심 긴장이다. 미메시스의 첫째 의미는 외형의 복제이고, 둘째 의미는 본질적 구조의 형식적 재현이다. 둘째 의미에서 미메시스는 모방하는 것과 모방되는 것 사이에 자기 동일적 구조의 매핑(structural mapping)을 요구하며, 이 매핑이 성공할 때 모방은 진리의 한 양상이 된다. 본 연구는 이러한 미학사적 양면성 위에서, 미메시스가 자기참조라는 형식 동형 구조로 격상될 수 있음을 보이고자 한다.

본 연구의 3 단계 모델은 미메시스의 이 둘째 의미를 형식 동형성의 차원에서 재현한다. 자기참조란 체계가 자기 자신을 자기 내부에 모방하는 행위이며, 이때의 모방은 외형의 복제가 아니라 구조의 자기 동일적 매핑이다. 괴델의 명제 G가 자기 자신의 증명 불가능성을 산술 언어로 진술할 때, 에셔의 「판화 갤러리」가 자기 자신을 자기 안에 포함할 때, 바흐의 「콘트라퐁크투스 XIV」가 BACH라는 작곡가의 이름을 음으로 박을 때, 트랜스포머의 induction head가 시퀀스 내 자기 모방 회로를 만들 때 — 이 네 경우에서 자기 모방은 진리 접근의 형식이며, 환원적 단순성으로부터 환원될 수 없는 메타-수준의 진리(괴델 불완전성, 시각적 무한, 음악적 무한, 창발적 능력)에 도달하는 길이다.

따라서 본 연구는 플라톤의 표면적 미메시스 비판(『국가』 제 10 권)을 부정하는 것이 아니라, 플라톤 미학 자체의 보다 깊은 층위(『티마이오스』, 『심포지엄』)에서 이미 잠재되어 있던 미메시스의 적극적 의미를 형식 동형성의 차원에서 명시화한다. 미메시스는 진리로부터의 이격이 아니라, 자기참조라는 형식을 통해 진리에 접근하는 방법이다. 이러한 재해석은 제 7장 제 4 절에서 4 영역 형식 동형성이 완성된 후 다시 회수된다.

2.4 차이와 반복

들뢰즈는 『차이와 반복』(1968)에서 단순 반복이 아닌 반복 속의 차이가 사유의 핵심 운동임을 주장하였다(Deleuze, 1968/1994). 본 연구의 자기참조 구조는 들뢰즈의 이 통찰과 형식적으로 공명한다.

에셔의 테셀레이션에서 반복되는 형상들은 결코 동일하지 않다. 평면결정군의 규칙은 동일하나, 각 위치에서 형상은 인접 형상과의 관계 속에서만 정의된다. 바흐의 푸가에서 주제가 모방, 역행, 확대, 축소로 반복될 때, 각 등장은 동일 주제가 다른 시간적 위치에서 다른 화성적 맥락에 놓이는 차이의 사건이다. 괴델 numbering 에서도 명제 G는 자신을 지

시하지만, 지시하는 G와 지시되는 G는 형식체계 F 내부와 F에 대한 메타-언급이라는 다른 층위에 있다. 트랜스포머의 induction head는 패턴 ‘AB...A’ 다음에 ‘B’를 예측할 때, 두 ‘A’가 시퀀스 위치는 다르나 모델 내부에서 동일성-차이의 동시성을 처리한다.

곧 TRIH의 자기참조는 차이를 보존하는 반복이며, 이로부터 창발이 발생한다. 들뢰즈적 의미의 차이 생성이 네 영역에서 형식적으로 동일한 메커니즘으로 작동한다는 것이 본 연구의 한 함의이다.

2.5 동양 사상의 기여 — 중관학과 자기참조

본 연구가 제안하는 TRIH는 서양 학술 전통의 자기참조 담론(호프스태터, 토노니, 노스호프 등)을 형식 동형성의 차원에서 통합하지만, 동양 사상, 특히 나가르주나(Nāgārjuna, 龍樹, 약 150-250)의 중관학(中觀學, Madhyamaka)이 다룬 자기참조 구조는 서양 전통이 도달하지 않은 지점을 비춘다. 본 절에서는 중관학의 두 핵심 개념 — 연기(緣起, pratītyasamutpāda)와 사구분별(四句分別, catuṣkoṭi) — 이 TRIH의 이론적 토대로서 어떤 기여를 하는지를 정리한다(Garfield, 1994; Priest, 2010; 김성철, 2004, 2019 참조).

2.5.1 연기와 자기참조의 형식적 공명

연기설은 모든 존재가 독립된 자성(自性, svabhāva)을 갖지 않고, 다른 것과의 상호의존(pratītyasamutpāda) 속에서만 정의된다고 본다. 이것이 있을 때 저것이 있고, 이것이 일어날 때 저것이 일어난다(此有故彼有 此起故彼起). 곧 모든 존재 X의 의미는 X 외부의 다른 모든 것 $\neg X$ 와의 관계망 속에서만 성립한다.

이 구조는 TRIH의 자기참조 단계와 형식적으로 공명한다(Garfield, 1994). 자기참조 회로 σ 는 체계 S의 일부 또는 전체를 S 내부에서 지시한다. 그런데 σ 가 가리키는 ‘자기’는

σ 를 포함한 S 전체이며, σ 는 자신을 정의하기 위해 자신이 속한 S 를 참조해야 한다. 곧 σ 의 의미는 σ - S 관계망 속에서만 성립한다. 에셔의 「그리는 손」에서 손 A는 손 B를 그릴 때만 손 A로 정의되며, 손 B는 손 A를 그릴 때만 손 B로 정의된다. 괴델의 명제 G는 형식체계 F 내부에서 자신의 괴델 수를 참조할 때만 G로 정의된다. 어느 한쪽도 독립적 자성을 갖지 않으며, 양자의 상호 지시 관계가 곧 자기참조 회로의 본질이다.

연기설과 자기참조의 이 형식적 공명은 본 연구의 한 학술적 기여이다. 자기참조 구조는 서양 형식논리에서 종종 역설(paradox)이나 무한 후퇴(infinite regress)로 평가되어 왔으나, 종관학의 시각에서 그것은 모든 존재의 정상적 존재 양식이다. 자기참조는 비정상이라 아니라, 비분해성(irreducibility) 그 자체이다(김성철, 2004 참조).

2.5.2 사구분별과 형식체계의 한계

나 가르주나의 사구분별(catuṣkoṭi)¹은 네 명제 — A 이다, A 아니다, 둘 다이다, 둘 다 아니다 — 를 모두 다루는 논리 형식이다. 서양의 고전 논리는 이가원리(bivalence, 모든 명제는 참·거짓 중 정확히 하나의 값을 가진다)에 따라 셋째와 넷째 명제를 배제하지만, 사구분별은 이들을 정당한 논리적 가능성으로 받아들인다. 프리스트(Priest, 2010)는 이를 현대 비고전 논리, 특히 비일관 논리(paraconsistent logic) 또는 다치 논리(many-valued logic)의 관점에서 분석하였다(김귀옥, 2019; 김성철, 2004 도 참조).

이 사구분별의 형식 구조는 괴델 명제 G와 흥미로운 비교 지점을 제공한다. G는 ‘G는 F에서 증명 불가능하다’라고 주장한다. 만약 G가 F에서 증명 가능하다면, G는 자기 모

¹ 산스크리트 catuṣkoṭi(चतुष्कोटि)는 ‘넷(catur) + 끝(koṭi)’의 합성어로 ‘네 모서리’ 또는 ‘네 극’을 뜻한다.

한역 불경에서는 사구분별(四句分別) 또는 사구(四句)로 옮겨지며, 본 논문은 학술적 합의에 따라 산스크리트 표기를 우선 사용하고 한자 표기를 병기한다.

순이다(둘째 명제 ‘A 아니다’). 만약 G가 F에서 증명 불가능하다면, G는 참이지만 F 내부에서 그 사실이 확인되지 않는다(첫째 명제 ‘A 이다’이되, F 내부에서는 미결정). 이때 G는 서양 형식논리의 이가(二價) 체계 내에서 명확한 진리값을 부여할 수 없는 명제가 되며, 사구분별의 둘째 또는 셋째 영역에 속한다. 수학 집합론의 역설과 중관학 반논리학 사이의 형식적 공명은 본 연구의 형식 동형성 주장과 같은 방향의 선행 작업으로 볼 수 있다(김성철, 2019 참조).

본 연구는 사구분별이 괴델의 정리를 직접 예측했다고 주장하지 않는다. 그러나 형식 체계가 자기참조를 통해 도달하는 메타-진리가 이가 논리로 환원될 수 없다는 점에서, 사구분별이 다루는 논리 형식과 괴델이 입증한 형식체계의 한계는 같은 종류의 구조적 통찰을 공유한다. 이는 비고전 논리 연구가 동양 사상의 형식적 재발견과平行하게 진행된 20세기 논리학사의 한 측면이기도 하다(Priest, 2010).

더 나아가 사구분별의 셋째 양상(‘A 이면서 동시에 A 아니다’)과 넷째 양상(‘A도 아니고 A 아닌 것도 아니다’)은 형식체계가 자기 자신을 가리키되 그것을 외연적으로 진술하지 않을 때 가장 정밀하게 구현된다. 자기참조는 그 자신을 명시적 메타-진술로 표명하는 순간 외부에서의 진술이 되어 자기참조의 양상을 잃는다. 오직 구조의 침묵 속에서만 형식체계는 자기 자신으로 머물며, 이는 사구분별이 형식 차원에서 가장 정밀하게 보여주는 양상이다.

2.5.3 진리 접근의 두 형식 — 동양과 서양의 만남

본 절의 결론은 다음과 같다. 자기참조 구조는 진리에서 멀어지는 길이 아니라, 진리에 접근하는 한 형식이다. 서양 전통에서 이는 플라톤 미메시스의 둘째 의미(§2.3 참조)와 괴델의 메타-진리(§5.3 참조)로 나타난다. 동양 전통에서 이는 연기설의 비분해적 상호의존

성과 사구분별의 비이가적(non-bivalent) 논리 형식으로 나타난다. 두 전통은 자기참조라는 형식 구조 위에서 만난다.

본 연구의 TRIH는 동양 사상의 재발견을 주장하지 않는다. TRIH는 네 영역(시각·청각·논리·계산)의 형식 동형성을 입증하는 독립된 가설이다. 그러나 본 절에서 짚은 동양 사상과의 구조적 공명은 TRIH가 단순한 서양 학술의 산물이 아니라, 인간 사유 전통이 자기참조와 진리의 관계를 다뤄온 보다 보편적 흐름의 한 형식적 정식화임을 시사한다. 이 공명은 제 7장 제 5 절에서 4 영역 형식 동형성이 완성된 후 다시 정리된다.

3. 사례 1 — 에셔: 시각의 자기참조


3.1 환원적 기하학: 알함브라에서 콕서터까지

마우리츠 코르넬리스 에셔(M.C. Escher, 1898-1972)의 작업은 환원적 출발점을 가진다. 그는 1922년 스페인의 알함브라 궁전을 처음 방문하여 무어인이 남긴 기하학적 타일을 모사하였고 [도 2], 1936년의 재방문에서 본격적인 평면 분할(tessellation) 연구로 들어선다(Schattschneider, 2010). 그는 자신을 수학자가 아니라고 자처하였으나, 1930년대 후반에 수학자 폴야(George Pólya)의 17개 평면결정군(plane crystallographic groups)² 분류 [도 3]를 접하고 이를 작업의 형식적 기반으로 삼는다.

² 평면결정군은 영문권에서 wallpaper group으로도 불리며, 2차원 평면을 빈틈없이 채우는 대칭군의 분류이다. 이 분류는 1891년 페도로프(E.S. Fedorov)가 처음 완성하였고, 폴야(1924)가 결정학적 관점에서 17개로 정리하였다. 17이라는 수는 평면 위의 가능한 모든 대칭 조합(병진, 회전, 반사, 미끄럼 반사)의 유한한 조합 가능성에서 도출되며, 임의의 평면 반복 패턴은 반드시 이 17개 군 중 하나에 속한다는 점이 그 수학적 핵심이다.

3.2 자기참조의 시각화: 「그리는 손」과 「판화 갤러리」

에셔의 자기참조 작품들 중 가장 명시적인 것은 1948 년 작 「그리는 손(Drawing Hands)」 [도 4]이다. 두 손이 서로를 그린다. 왼손은 오른손의 소맷부리를 그리고 있고, 오른손은 왼손의 소맷부리를 그리고 있다. 어느 손이 먼저인지, 어느 손이 그려진 것이고 어느 손이 그리는 것인지 결정할 수 없다. 이는 TRIH의 3 단계 모델로 명시적으로 분석된다. 환원 단계에서 작품은 두 손이라는 객체와 펜·종이라는 정상적 인과 관계로 출발한다. 자기참조 단계에서 손 A가 손 B를 그리고 손 B가 손 A를 그리는 순환 구조가 형성되며, 인과의 외부 시작점이 사라진다. 창발 단계에서 관찰자의 시각 인지 체계는 이 자기 창조의 역설을 통합 처리하지 못하면서, 자기 자신을 그리는 손이라는 새 의미 차원이 출현한다. 이 메타 차원은 환원적 분석으로 도달할 수 없으며, 작품 외부 관찰자에게서만 인식된다.



[도 4] M.C. 에셔, 「그리는 손(Drawing Hands)」, 1948, 석판화, 28.2 × 33.2 cm (© The M.C. Escher Company B.V., Baarn)


보다 정교한 메타-수준 자기참조는 1956 년 작 「판화 갤러리(Printententoonstelling, Print Gallery)」 [도 5]에서 구현된다. 한 청년이 갤러리에서 판화 한 점을 들여다본다. 그 판화 안에는 항구 도시가 그려져 있고, 그 도시의 한 건물 안에는 그 갤러리가 있으며, 그 갤러리 안에는 그 청년이 있다. 작품은 자기 자신을 자기 안에 포함한다. 흥미롭게도 에서는 이 작품의 중앙에 의도적 공백을 남겼는데, 2003 년 라이덴 대학의 두 수학자 헨드릭 렌스트라(Lenstra)와 바르트 더 스미트(de Smit)는 이 공백이 닫힌 형식의 등각 변환(conformal mapping)으로 정확히 채워질 수 있음을 보였다(de Smit & Lenstra, 2003). 작품은 단순한 시각적 농담이 아니라, $z \rightarrow z^\alpha$ 형태의 복소 함수로 형식화 가능한 메타-수준 자기참조의 정밀한 구현이다. 에서의 자기참조 작업은 직관을 넘어 형식적 구조에 닿아 있었다.



[도 5] M.C. 에서, 「판화 갤러리(Printententoonstelling)」, 1956, 석판화, 31.9 × 31.9 cm

비유클리드 기하의 시각예술적 의의를 다룬 선행 연구들도 에서의 자기참조 작업이 단순한 수학의 시각화에 그치지 않고, 평면이라는 매체의 자기지시적 한계를 드러내는 인

식론적 작업임을 지적해왔다. 「폭포(Waterfall)」 [도 6]와 「올라가기와 내려가기(Ascending and Descending)」 [도 7]는 펜로즈 삼각형과 펜로즈 계단을 응용한 불가능 도형의 사례로(Penrose & Penrose, 1958), 각 부분은 국소적으로 정합적이지만 전체는 비정합적이라는 시각적 자기 부정 구조를 보여준다.




[도 6] (왼쪽) M.C. 에셔, 「폭포(Waterfall)」, 1961, 석판화, 38 × 30 cm

[도 7] (오른쪽) M.C. 에셔, 「올라가기와 내려가기(Ascending and Descending)」, 1960, 석판화, 35.5 × 28.5 cm

3.3 쌍곡적 무한: 「원형 한계」 연작

자기참조 구조의 가장 정교한 시각적 결과는 「원형 한계(Circle Limit)」 연작(1958-1960)에서 확인된다 [도 8], [도 9]. 푸앵카레 디스크 모델에서 원의 중심으로부터 가장자리로 갈수록 쌍곡 거리상 같은 길이의 선분이 유클리드 평면상에서는 점차 짧아진다. 에셔는 이 위에 물고기 또는 천사·악마 형상을 채워, 유한한 원판 안에 무한히 많은 형상을 그렸다. 각 형상은 외형상 다르지만 쌍곡 거리상으로는 모두 동일한 크기이다.



[도 8] (왼쪽) M.C. 에셔, 「원형 한계 I(Circle Limit I)」, 1958, 목판화, 직경 41.8 cm

[도 9] (오른쪽) M.C. 에셔, 「원형 한계 IV(Circle Limit IV, 천사와 악마)」, 1960, 목판화, 직경 41.6 cm

이는 TRIH 3 단계의 완전한 시각적 구현이다. 환원 단계로서 쌍곡 거리 함수라는 단일 규칙이 주어진다. 자기참조 단계로서 형상이 자기 자신의 축소된 사본을 무한히 가장자리 방향으로 반복하는 자기유사성(self-similarity)이 나타난다. 창발 단계로서 유한 평면 안에 무한 개수의 형상이 존재한다는 시각적 무한이 출현한다.

이 자기유사성 구조는 만델브로(Mandelbrot, 1982)가 프랙탈(fractal) 기하학으로 일반화한 자기유사·척도불변 구조와 개념적으로 평행하다. 다만 「원형 한계」의 자기유사성은 쌍곡 등거리 변환의 이산군이 생성하는 규칙적 쌍곡 타일링에 속하고, 만델브로 집합·줄리아 집합의 자기유사성은 해석함수의 반복 적용이 낳는 준자기유사(quasi-self-similarity)로서 수학적으로는 서로 다른 대상이다. 그럼에도 두 경우 모두 유한한 영역 안에서 척도에 따라 무한히 반복되는 자기참조 구조를 공유하며, 이 점에서 에셔가 시각적 직관으로 도달한 구조는 이후 수학이 형식적으로 탐구한 자기유사 구조의 시각적 선례로 읽을 수 있다. 곧 에셔의 작업은 단순한 미술사적 사건이 아니라, 자기참조의 시각적 형식화로서 수학·물리학·인지과학과 형식적으로 통합 가능한 학술적 대상이다.

3.4 시각 신경의 계층적 자기참조

본 절은 에서 작품의 자기참조 구조가 인간 시각 신경의 자기참조 구조와 어떻게 형식적으로 매핑되는지를 정리한다. 이는 제 4 장 제 4 절이 청각 영역에서 정리한 신경-형식 매칭과 평행한 분석이며, 제 7 장 제 3 절에서 시각·청각 양 영역의 통합으로 회수된다.

인간의 시각 처리는 망막의 광수용기(rod, cone) → 시신경 → 외측슬상핵(LGN) → 1 차 시각 피질(V1) → V2 → V4 → 측두엽 IT 피질로 이어지는 계층 구조를 갖는다(Kandel 외, 2013, ch.25-28). V1 은 빛 자극에서 방향성 있는 가장자리(oriented edges), 공간 주파수, 양안 시차 같은 1 차 특징을 추출하고, V2 는 V1 의 출력을 다시 받아 환영적 윤곽(illusory contours), 도형-바탕 분리 같은 2 차 특징을 추출하며, V4 는 색 항상성과 곡면 모양을 처리한다. 각 단계는 자기 이전 단계의 출력을 자기참조적으로 재처리하여 메타-수준 표현을 생성한다.

에서의 자기참조 작품들이 시각적으로 강력하게 작용하는 이유는 이 시각 신경의 계층적 자기참조 구조 자체를 자기 자신에게 되돌려 보내기 때문이다. 「그리는 손」의 경우, V1·V2 수준에서는 두 손과 펜이라는 정상적 객체 분리가 처리된다. 그러나 V4 와 그 이상의 측두엽 IT 피질에서 “이 손이 저 손을 그리고, 저 손이 이 손을 그린다”는 인과 관계의 자기참조 고리가 검출되며, 이는 시각 시스템이 통상 처리하는 외부 객체의 인과 구조와 충돌한다. 인지적 불일치가 발생하면서 동시에, 그 불일치 자체가 작품의 의미가 된다. 「판화 갤러리」에서는 한 걸음 더 나아가 시각 장면 전체가 자기 자신을 포함하므로, 시각 통합 처리는 닫힌 고리 안에 자기 자신을 발견한다. 「폭포」와 「올라가기와 내려가기」의 경우 V1 수준의 국소 가장자리 처리는 정합적이나 IT 피질 수준의 전역 3 차원 통합이 실패하며, 그 실패가 곧 작품의 핵심 인상이 된다.

곧 에셔의 자기참조 작품은 시각 신경 처리의 어느 단계에서든 자기참조 고리가 형성되거나 정합성이 깨질 때 우리가 무엇을 ‘보는’지를 시각예술로 실험한 작업이다. 이는 에셔의 직관이 단순한 그래픽 기교가 아니라 시각 신경의 자기참조적 작동 원리에 닿아 있었음을 의미하며, 본 연구의 TRIH 관점에서 보면 에셔는 시각 영역에서 자기참조의 형식 동형성을 시각적 실험으로 입증한 선구자이다.

본 절의 결론은 다음과 같다. 시각의 자기참조 구조는 단지 에셔 작품 안에 머물지 않고, 그 작품을 인식하는 우리 시각 신경 자체에 다층적으로 새겨져 있다. 이 결론은 제 4 장 제 4 절의 청각 영역 결론과 형식적으로 평행하며, 두 영역의 통합 분석은 제 7 장 제 3 절에서 다뤄진다.

4. 사례 2 — 바흐: 청각의 자기참조

4.1 대위법의 환원적 본질 — 정수 진동비에서 대위법 규칙까지

요한 제바스티안 바흐(J.S. Bach, 1685-1750)의 음악은 대위법(counterpoint)이라는 환원적 규칙 체계 위에 서 있다. 대위법은 둘 이상의 독립된 선율선이 동시에 진행될 때 따라야 할 규칙들의 집합이다. 협화음과 불협화음의 처리, 5도 응답, 모방의 시간 간격, 역행 및 전위의 가능성 등이 그 규칙이다. 5도 응답이란 한 성부에서 등장한 주제(主題, subject)가 다음 성부에서 완전 5도 위로 응답(answer)되는 모방 기법이며, 이는 푸가(fugue) 형식의 환원적 토대이다(Schulenberg, 2006). 푸가 자체는 르네상스 후기에서 바로크 초기에 걸친 리체르카레(ricercare) 양식에서 진화한 형식이며, 바흐의 푸가는 이 16-17세기 건반 대위법 전통의 정점에서 환원적 형식과 자기참조의 결합이 정교하게 구현된 사례이다(이웅희, 2011 참조).

그런데 대위법의 이 규칙 체계 자체가 환원 가능한 보다 깊은 토대를 가진다. 그것은 정수 진동비(integer frequency ratio)라는 물리적 사실이다. 두 음의 주파수가 단순한 정수비(예: 2:1 옥타브, 3:2 완전 5도, 4:3 완전 4도)를 이룰 때 두 음의 파형은 주기적으로 정확히 겹쳐 협화음(consonance)을 형성하며, 정수비를 이루지 않을 때 두 파형은 비주기적 간섭을 일으켜 불협화음(dissonance)을 형성한다. 이 사실은 피타고라스가 기원전 6세기에 일현금(monochord) 실험으로 발견하였다고 전해지며, 현대 음향학에서 자연 배음렬(harmonic series)의 정수배 구조로 정식화되었다.

자연 배음렬은 한 기본음(fundamental)이 진동할 때 동시에 발생하는 정수배 주파수 성분의 무한 수열이다. 기본음 f 를 진동시키면 $2f, 3f, 4f, 5f, \dots$ 의 배음(overtone)이 자동적으로 발생한다. 이 중 가장 강한 배음은 $2f$ (옥타브)와 $3f$ (완전 5도 위 옥타브)이다(Helmholtz, 1885).³ 곧 자연계의 어떤 진동체도 자기 자신 안에 자기의 배수 주파수들을 동시에 포함한다. 이는 청각 영역의 첫 번째 자기참조 구조이다. 단일 음 자체가 이미 자기의 정수배 사본들을 내포하는 자기 유사 구조(self-similar structure)인 것이다.

대위법의 규칙 — 특히 5도 응답 — 은 이 자연 배음렬의 자기참조 구조를 음악 형식의 차원에서 명시화한 것이다. 주제가 5도 위에서 응답될 때, 그 응답은 주제의 가장 강한 자연 배음($3f$ 의 옥타브 환원)에 다름 아니다. 5도 응답은 임의적 음악 관습이 아니라, 자연 배음의 자기참조 구조를 작곡 규칙으로 형식화한 결과이다. 푸가 형식의 “자연스러움”이

³ 헬름홀츠의 원저는 *Die Lehre von den Tonempfindungen als physiologische Grundlage für die Theorie der Musik* (Braunschweig: Vieweg, 1863)이며, 본 논문은 Ellis의 영역본(1885, 4판)을 인용한다. 원본은 19세기 음향학·생리학·음악학을 통합한 고전적 저작으로, 협화음·불협화음의 물리적·생리학적 토대를 처음으로 체계화하였다.

단순한 미적 관습이 아니라 물리적 자기참조 구조에 정초되어 있다는 사실은, 바흐 음악이 왜 시대를 넘어 보편적 호소력을 갖는지에 대한 한 답이 된다.

TRIH의 환원 단계에서, 바흐의 모든 푸가, 카논, 정선율은 단일 동기와 대위법 변형 규칙들의 유한한 집합으로 환원된다. 그러나 그 대위법 규칙 자체는 자연 배음렬이라는 물리적 자기참조 구조로 더 깊이 환원된다. 곧 바흐의 환원적 토대는 두 층으로 구성된다. 표면 층은 작곡 규칙(5도 응답, 대위법)이고, 심층 층은 정수 진동비와 자연 배음의 물리적 자기참조 구조이다. 이 이중 토대 위에서 바흐의 자기참조와 창발이 전개된다.

4.2 무한 상승의 자기참조: 「끝없이 상승하는 카논」

『음악의 헌정(Musikalisches Opfer)』(BWV 1079, 1747)의 한 부분인 「조성을 따르는 카논(Canon per Tonos)」, 일명 「끝없이 상승하는 카논(Endlessly Rising Canon)」은 바흐 자기참조의 대표적 사례 중 하나이다 [도 10]. 곡은 c 단조에서 시작하여 한 사이클이 끝날 때 d 단조로 한 음 높아진 상태로 처음으로 돌아간다. 그러면 다시 같은 사이클을 d 단조에서 시작하면 e 단조로 끝나고, 다시 e 단조에서 시작하면 f# 단조로 끝난다. 여섯 사이클을 거치면 옥타브 위 c 단조로 회귀하여 곡은 끝없이 상승할 수 있는 구조가 된다.

무한상승 카논 (Canon a 2 per tonos) — 『음악의 현정』 BWV 1079

왕의 주제 위 2성 카논 — 매 주기 장2도 상승, 6주기 뒤 옥타브 위 원조 회귀 (제1주기)

c → d → e → f# → g# → b → c' (장2도 사다리)

반복마다 +M2 (ad infinitum)

“Ascendenteque Modulatione ascendat Gloria Regis” — 원보 명문

[도 10] J.S. 바흐, 「조성을 따르는 카논(Canon per Tonos)」 BWV 1079 발췌 보표 — 6 사이클 상승 구조 분석 (저자 작성, music21)

이는 TRIH의 3 단계 모델로 정밀하게 분석된다. 환원 단계에서 곡은 단일 멜로디 동기와 한 음씩 상승하는 단순한 변형 규칙으로 출발한다. 자기참조 단계에서 멜로디는 자기 자신을 한 음 위에서 변형 반복하며, 여섯 번의 순환 후 정확히 한 옥타브 위의 시작 음높이로 회귀한다. 곡의 끝이 곧 곡의 시작과 동형(同形)이다. 창발 단계에서 청자는 끝없이 상승하는 음이라는 청각적 무한을 경험한다. 이는 환원적 규칙(한 음씩 상승)으로는 직접 도출되지 않는 메타-수준 경험이다.

흥미롭게도 이 청각 현상은 1964년 인지심리학자 셰퍼드(R.N. Shepard)가 발견한 셰퍼드 음(Shepard tone) 효과의 음악적 원형이다. 옥타브 관계의 여러 사인파를 적절히 중첩하면 인간의 청각 시스템은 그것을 무한히 상승 또는 하강하는 단일 음으로 지각한다(She

pard, 1964). 셰퍼드 음의 무한 상승 환영은 단순한 청각 착시가 아니라, 인간 청각 신경이 옥타브 관계라는 정수 진동비 구조에 자기참조적으로 반응한다는 사실을 시사한다. 곧 바흐의 「끝없이 상승하는 카논」은 음악적 자기참조 구조와 청각 신경의 자기참조적 정합성이 만나는 지점이며, 그 신경학적 기초는 본 장 제 4 절과 제 7 장 제 3 절에서 다룬다.

4.3 자기 이름의 박힘: 「푸가의 기법」콘트라퐁크투스 XIV

자기참조의 또 다른 정점은 바흐의 마지막 작품 『푸가의 기법(Die Kunst der Fuge)』(BWV 1080, 1750)의 중곡 「콘트라퐁크투스 XIV(Contrapunctus XIV)」이다 [도 11]. 이 4 중 푸가는 세 번째 주제로 B $\flat$ -A-C-B $\sharp$, 곧 독일어 음명 표기로 B-A-C-H 라는 작곡가 자신의 이름을 음 자체로 박아 넣는다. 그리고 이 자기 이름의 주제가 막 도입된 직후, 작품은 미완성으로 끝난다. 바흐는 이 작품을 미완성으로 남긴 채 사망하였다. 바흐의 아들 C.P.E. 바흐는 자필 악보의 마지막 페이지에 작곡자가 BACH 라는 이름을 대위법으로 도입한 지점에서 사망하였음을 메모로 남겼다(David & Mendel, 1998).

푸가의 기법 Contrapunctus XIV — B-A-C-H 진입 (mm.191-196)

제3주제 = 작곡가 이름의 음명 서명 · 악보는 m.239에서 끝김(미완)

B $\flat$ - A - C - B $\sharp$ = B - A - C - H

제3주제 진입: 테너, m.193 — 이후 m.239에서 자필보 중단

악보 인크딩: C. S. Sapp, github.com/craigsapp/art-of-the-fugue (BGA Band 25.1, 1878 기준)


[도 11] J.S. 바흐, 「콘트라퐁크투스 XIV」 BWV 1080 BACH 동기 부분 보표 (Bach-Gesellschaft Ausgabe Band 25.1(1878) 기반; 저자 조판·주석, music21·verovio)

이는 TRIH의 3 단계가 미완(未完)의 형태로 구현된 사례이다. 환원 단계로서 독일어 음명 체계라는 단순 코드가 주어진다. 자기참조 단계로서 작곡가가 자기 이름을 음으로 박아 넣는다. 창발 단계로서 미완성으로 끝난다는 사실 자체가 작품의 의미 일부가 되는 메타-수준 차원이 출현한다. 이 구조는 제 5장에서 다룰 괴델 명제 G의 자기 이름 인코딩과 형식체계 불완전성과 형식적으로 동형이다. 바흐의 생애 전반과 『푸가의 기법』의 작곡 맥락에 대한 음악학적 종합은 Williams(2016)에 정리되어 있다.

4.4 푸가 형식과 자기참조 — 청각 신경의 자기참조적 정합성

바흐의 푸가 일반은 자기참조 구조의 음악적 정식화 자체이다. 주제(subject)가 한 성부에서 도입되고, 다음 성부에서 5도 응답(자기 자신의 5도 변형)되며, 이어지는 성부들에서 모방, 역행, 전위, 확대, 축소의 변형으로 반복된다. 4성부 푸가에서 한 주제는 네 번 자기 자신을 만나며, 각 만남마다 화성적 맥락이 다르다. 곧 푸가는 차이를 보존하는 반복(들뢰즈)의 음악적 구현이다.

이 푸가적 자기참조가 가장 정교하게 확장된 사례는 『음악의 헌정』 중 「6성부 리체르카레(Ricercar a 6)」(BWV 1079)이다. 1747년 포츠담에서 프리드리히 대왕은 바흐에게 직접 주제(Thema Regium)를 제시하고 즉흥 푸가를 청하였으며, 바흐는 그 자리에서 3성부 푸가를 즉흥 연주한 뒤 6성부 푸가는 후에 완성하여 헌정하였다(David & Mendel, 1998). 4성부 푸가에서 주제가 자기 자신을 네 번 만난다면, 6성부 리체르카레에서는 단일한 왕의 주제가 여섯 성부에 걸쳐 시차를 두고 자기 자신과 마주친다 [도 12b]. 더욱이 헌정 악보에 인쇄된 라틴어 헌사 ‘Regis Iussu Cantio Et Reliqua Canonica Arte Resoluta’(왕의 명에 의한 노래와 나머지를 카논 기법으로 풀)의 머리글자는 RICERCAR라는 단어를 이룬다. 음악의 자기참조가 제목의 문자 층위로까지 확장된 사례이다.



[도 12b] J.S. 바흐, 「6 성부 리체르카레(Ricercar a 6)」 BWV 1079 제시부 주제 진입 구조(마디 1-27)
— 트랜스포머 인과적 자기집중 마스크와의 형식 평행 (저자 작성, music21·matplotlib)

가장 극단적인 자기참조 형식은 「게 카논(Crab Canon)」 BWV 1079 에서 구현되는데, 이
는 곡 전체가 정행과 역행 사이의 회문(palindrome) 구조로 작곡되어, 두 성부가 서로의 시
간 거울상으로 동시에 연주되는 순수 자기참조 구조이다 [도 12].

게 카논 (Canon a 2 cancrizans) — 『음악의 현정』 BWV 1079
왕의 주제로 여는 18마디 선율과 그 역행의 동시 결합 — 시간 역전 자기참조

선율 전체 (시간 순방향)

정행

역행

11

정행

역행

16

정행

역행

← 같은 선율의 역행 (시간 역방향)

$P_2(t) = P_1(T - t)$

[도 12] J.S. 바흐, 「게 카논(Crab Canon)」 BWV 1079 회문 구조 시각화 (저자 작성, music21)

이 자기참조 구조는 제 6 장의 트랜스포머 자기집중(self-attention) 메커니즘과 흥미로운 형식적 평행을 이룬다[도 12b]. 푸가에서 주제가 자신의 변형을 시간 위에서 만나는 방식은, 트랜스포머가 시퀀스 위치 i 에서 위치 $j(j \leq i)$ 를 자기집중으로 참조하는 방식과 형식적으로 평행하다. 양쪽 모두 단순 규칙에 자기참조를 더하여 복잡한 결과로 나아가는 패턴을 따른다.

4.4.1 청각 신경의 주파수 지도 — 자기참조의 신경학적 토대

푸가의 자기참조 구조가 인간 청자에게 미적 호소력을 갖는 이유는 무엇인가? 본 절은 이 질문에 대해 청각 신경과학의 두 발견 — 주파수 지도(tonotopic map)와 화음 보상 시스템 — 이 부분적인 답을 제공함을 정리한다.

인간의 청각 처리는 외이 → 중이 → 내이의 달팽이관(cochlea)을 거쳐 청신경 → 1 차 청각 피질(A1)로 이어진다. 달팽이관 내부의 기저막(basilar membrane)은 소리의 주파수에 따라 서로 다른 위치에서 진동한다. 저주파(20-200 Hz)는 기저막의 끝(apex)에서, 고주파(2,000-20,000 Hz)는 시작 부분(base)에서 진동을 유발한다(Kandel 외, 2013, ch.30). 기저막 위에는 유모세포(hair cell)가 줄지어 있어, 특정 주파수에 자기 위치에서만 활성화된다. 이는 주파수와 신경 위치 사이의 일대일 매핑이며, 1 차 청각 피질 A1 에서도 이 매핑이 보존된다. 이를 주파수 지도 또는 음위상학적 지도(tonotopic map)라 한다(Kandel 외, 2013, ch.31).

주파수 지도의 본질은 청각 신경 자체가 정수 진동비 구조에 자기참조적으로 정렬되어 있다는 것이다. 두 음이 옥타브 관계(2:1)일 때 두 음에 반응하는 유모세포의 위치는 기저막상 정확한 비례 거리에 있으며, 1 차 청각 피질에서도 이 거리 관계가 보존된다. 곧 청각 신경의 공간적 구조 자체가 자연 배음렬의 자기참조 구조와 동형이다. 두 음의 정수 진동

비는 청각 신경 위에서 정수 거리 관계로 사상(寫像)되며, 이 사상이 청각의 자기참조적 정합성을 신경 차원에서 보장한다.

4.4.2 화음 보상 시스템과 자기참조적 정합성의 미적 코딩

정수 진동비가 청각 신경에 자기참조적으로 정렬되어 있다는 사실은, 협화음과 불협화음의 미적 차이를 신경학적으로 설명하는 토대를 제공한다. 협화·불협 등 음악의 정서적 처리에는 청각 피질뿐 아니라 측좌핵(nucleus accumbens), 편도체(amygdala), 안와전두피질(orbitofrontal cortex) 같은 보상·정서 관련 영역이 관여한다(Koelsch, 2014). 특히 강한 쾌감을 유발하는 음악을 들을 때 측좌핵을 포함한 중변연계 보상 회로에서 도파민(dopamine)이 분비된다는 것이 신경영상으로 확인되었다(Salimpoor 외, 2011). 협화음의 단순 정수 진동비(2:1, 3:2, 4:3)가 이러한 보상 처리와 정합적으로 맞물린다는 것이 본 절의 해석이다.

반면 불협화음에서는 두 파형이 비주기적 간섭을 일으켜 비트(beats)라 불리는 현상이 발생한다. 청각 신경은 이 비주기적 간섭을 자기참조적 정합성의 깨짐으로 처리하며, 편도체가 활성화되어 긴장감이나 불쾌감이 발생한다. 이를 청각적 불일치(auditory dissonance)라 한다(Koelsch, 2014). 곧 우리 청각 시스템은 자기참조 구조의 정합성을 미적 쾌감으로, 그 깨짐을 미적 긴장으로 코딩한다.

이 신경학적 사실은 TRIH 관점에서 다음과 같이 정리된다. 청각의 자기참조 구조는 단지 음악 형식의 차원에 머물지 않고, 청각 신경 자체에 물리적으로 새겨져 있다. 푸가의 자기참조 — 주제의 자기 모방, 5도 응답, 역행과 전위 — 가 우리에게 ‘아름답다’고 느껴지는 이유는, 이 음악적 자기참조가 우리 청각 신경의 자기참조적 정합성과 형식적으로 일치하기 때문이다. 단, 단순 협화음의 정합성과는 달리, 푸가는 자기참조를 다층 변형으

로 발전시키므로 단순 정합성 이상의 인지적 도전을 동반한다. 따라서 푸가가 유발하는 미적 경험은 청각 신경의 1 차 자기참조 정합성에 더해, 인지 처리 과정에서의 예측·해소 패턴이 결합된 결과이다(Koelsch, 2014).

4.4.3 음악적 자기참조와 신경 자기참조의 형식 매칭

이상의 분석은 TRIH의 형식 동형성 주장에 새로운 차원을 추가한다. 본 장은 단지 바흐의 음악이 자기참조 구조를 갖는다는 형식적 입증을 넘어, 그 자기참조가 청각 신경의 자기참조 구조와 형식적으로 매칭됨을 보였다. 곧 바흐 음악은 인간 청각 신경 자체가 갖는 자기참조 구조의 미적 구현이다.

이 매칭은 단순한 비유가 아니다. 그것은 (1) 음악 형식의 자기참조 규칙(5도 응답, 역행, 카논), (2) 자연 배음의 물리적 자기참조 구조(정수 진동비), (3) 청각 신경의 주파수 지도(tonotopic map), (4) 화음 보상 시스템의 신경 코딩이라는 네 층이 모두 동일한 형식 — 자기참조적 정합성 — 위에서 작동하는, 다층적 형식 동형성이다. 본 연구는 이 다층 동형성을 제 7장 제 3 절(의식 연구 함의)에서 시각 영역의 V1-V4 계층 처리와 함께 다시 통합한다.

5. 사례 3 — 괴델: 논리의 자기참조

5.1 형식체계로의 수학 환원

19세기 말 칸토어의 집합론과 러셀의 역설 발견 이후, 수학의 토대를 명확히 하려는 욕망은 형식주의(formalism)라는 야심을 낳았다. 다비트 힐베르트(David Hilbert, 1862-1943)는 1900년 파리 강연과 1920년대 힐베르트 프로그램을 통해, 모든 수학적 명제를 유한한

공리 체계 F 와 유한한 추론 규칙으로 환원하고, F 의 무모순성과 완전성을 F 내부에서 증명하려 하였다.

이 환원적 야심의 정점은 화이트헤드와 러셀의 『수학원리(Principia Mathematica)』(1910-1913)이다. 그 거대한 세 권의 책은 수학 전체를 형식 논리로 환원하려는 가장 정교한 시도였다. 형식체계 F 는 일정한 형식 언어, 유한한 공리 집합, 추론 규칙(전건긍정 modus ponens 등)으로 구성되며, F 의 명제는 공리에서 추론 규칙을 유한 회 적용하여 도출되는 식이다.

이것이 TRIH의 환원 단계에 해당한다. 수학이라는 거대한 의미 공간이 유한한 기호와 규칙의 집합으로 환원 가능하다는 가정이다. 그러나 이 환원의 한계는, 환원 자체가 F 내부에서 자기 자신을 다룰 수 있게 되는 순간에 드러난다.

5.2 괴델 numbering 과 명제 G 의 자기참조


1931년 쿠르트 괴델(Kurt Gödel)은 25세의 나이로 「『수학원리』와 관련 체계의 형식적으로 결정 불가능한 명제들에 관하여(Über formal unentscheidbare Sätze der Principia Mathematica und verwandter Systeme)」를 발표하였다(Gödel, 1931). 그의 핵심 아이디어는 괴델 numbering이라 불리는 인코딩 기법이다.

괴델은 형식체계 F 의 모든 기호, 모든 식, 모든 증명열에 고유한 자연수(괴델 수)를 할당하였다. 예를 들어 기호 $\neg$ 에 1, $\forall$ 에 2, $\exists$ 에 3 등을 할당하고, 식과 증명열에는 소인수분해의 유일성을 이용한 합성수를 할당한다. 이로써 F 의 모든 메타-수준 진술(예컨대 ‘식 φ 는 F 에서 증명 가능하다’)은 F 내부의 산술 명제로 반사(reflection)된다. F 는 F 자신에 대해 F 내부에서 말할 수 있게 된다.

이것이 TRIH의 자기참조 단계의 가장 순수한 논리적 구현이다. 형식체계가 자기 자신을 자기 내부에 코드화하는 것이다. 이 자기 코드화 위에서 괴델은 다음과 같은 명제 G 를 구성하였다.

G : ‘괴델 수가 $\ulcorner G \urcorner$ 인 명제는 F 에서 증명 불가능하다.’

여기서 $\ulcorner G \urcorner$ 는 명제 G 자체의 괴델 수이다. 곧 G 는 자기 자신이 F 에서 증명 불가능함을 F 의 산술 언어로 진술한다 [도 13].



[도 13] 괴델 명제 G 의 자기참조 구조 도식 — Gödel numbering을 통한 메타-수준 반사 (저자 작성)

이 명제의 자기참조 구조는 시각적으로 에서 「그리는 손」과 동형이며, 청각적으로 바흐 「콘트라퐁크투스 XIV」의 B-A-C-H 박힘과 동형이다. 셋 모두 체계가 자기 이름 또는 자기 모습을 자기 내부에 박는다는 동일한 형식을 가진다.

5.3 메타-진리의 창발: 불완전성

명제 G 의 창발 단계는 다음과 같이 전개된다. F 가 무모순이라 가정하자. 만약 G 가 F 에서 증명 가능하다면, G 는 ‘ G 는 증명 불가능하다’를 주장하므로 모순이다. 따라서 G 는 F 에서 증명 불가능하다. 그런데 G 가 F 에서 증명 불가능하다면, G 의 진술 내용(‘ G 는 증명 불가능하다’)이 정확히 참이다. 곧 G 는 참이지만 F 에서 증명 불가능하다. 이것이 괴델의 제 1 불완전성 정리의 핵심이다(Nagel & Newman, 2001).

이때 G 의 진리는 F 내부에서는 도달할 수 없으며, 오직 F 에 대해 메타-수준에서 사유하는 외부 관찰자에게만 인식된다. 진리는 증명보다 크다. 이 메타-진리는 환원적 분석으로는 도출되지 않으며, 형식체계의 자기참조가 닫힌 고리를 형성할 때 비로소 출현하는 창발 속성이다. 곧 형식체계가 자기 자신과 어떤 구조를 공유할 때(자기 코드화) 그 체계는 필연적으로 불완전해진다는 것이 본 정리의 핵심 함의이다.⁴

괴델의 자기참조 구조는 한 걸음 더 나아간 함의를 낳는다. 같은 1931년 논문에서 괴델은 제 2 불완전성 정리를 증명하였다. 형식체계 F 가 무모순이라면, F 는 자기 자신의 무모순성(consistency)을 F 내부에서 증명할 수 없다는 것이다(Gödel, 1931). 제 1 정리가 ‘참이지만 증명 불가능한 명제가 존재한다’는 한계였다면, 제 2 정리는 체계가 자기 자신이 모순 없음을 스스로 보증할 수 없다는 자기참조의 더 깊은 한계를 드러낸다. 체계는 자기 자신을 자기 내부에 코드화할 수 있지만(자기참조), 바로 그 자기참조 능력 때문에 자기 자신의 건전성을 자기 안에서 확립할 수는 없다. 자기 정당화의 시도가 자기참조의 닫힌 고

⁴ 비트겐슈타인은 『논리철학논고』(1921)에서 문장의 구조와 그 문장이 주장하는 사실 구조가 어떤 것을 공유해야만 한다는 직관을 제시한 바 있는데, 괴델의 정리는 이 직관에 형식적 형태를 부여한다(이에 대한 분석은 선우환, 1995 참조).

리 안에 갇히는 것이다. 이는 어떤 자기참조 체계도 자기 자신만으로는 완결될 수 없음을 보여주며, 자기참조가 곧 자기 완결성을 의미하지는 않는다는 점에서 TRIH의 함의를 정밀하게 한정한다.

괴델 정리의 형식적 도출과 후속 논리학사적 의의에 대한 상세 해설은 Nagel & Newman(2001)과 Smith(2007)를 참조할 수 있다.

5.4 계산으로의 확장: 튜링의 정지 문제

괴델의 불완전성이 형식체계의 자기참조에서 비롯된 논리의 한계라면, 같은 자기참조 구조는 계산 가능성(computability)의 영역에서도 동일한 형식으로 반복된다. 1936년 앨런 튜링(Alan Turing, 1912-1954)은 힐베르트의 결정 문제(Entscheidungsproblem) — 임의의 수학 명제가 주어진 공리계에서 증명 가능한지를 유한한 기계적 절차로 판정할 수 있는가 — 를 다루기 위해, 오늘날 튜링 기계(Turing machine)라 불리는 계산의 형식 모델을 고안하였다(Turing, 1937).

튜링은 자기 자신을 입력으로 받을 수 있는 보편 기계(universal machine)를 구성하고, 칸토어의 대각선 논법(Cantor's diagonal argument)을 적용하여 다음을 증명하였다. 어떤 기계도 임의의 기계가 계산을 영원히 계속하는지 아니면 언젠가 멈추는지를 유한한 절차로 판정할 수 없다. 튜링 자신은 이를 순환 없는 기계(circle-free machine), 곧 출력을 무한

히 이어가는 기계인지를 판정하는 문제로 정식화하였으며, 오늘날 정지 문제(halting problem)로 알려진 결정 불가능성이 바로 이것이다.⁵

이 증명의 핵심은 괴델 명제 G와 형식적으로 동형이다. 만약 임의의 프로그램의 정지 여부를 판정하는 프로그램 H가 존재한다면, H를 자기 자신에 적용하여 ‘H가 정지한다고 판정하면 정지하지 않고, 정지하지 않는다고 판정하면 정지하는’ 모순적 프로그램을 구성할 수 있다. 자기 자신을 입력으로 받는 프로그램이 자기지시적 모순을 일으킨다는 이 구조는, 명제 G가 ‘자기 자신이 증명 불가능하다’고 진술하여 불완전성을 낳는 구조와 정확히 같다. 괴델의 G가 증명과 진리를 분리하였듯, 튜링의 정지 문제는 계산과 결정 가능성을 분리한다.

이 동형성은 TRIH의 관점에서 중요한 함의를 가진다. 논리(괴델)와 계산(튜링)은 서로 다른 영역이지만, 자기참조가 닫힌 고리를 형성할 때 체계 내부에서 결정 불가능한 한계가 출현한다는 동일한 형식을 공유한다. 그리고 이 계산 가능성의 자기참조 구조는 제 6장에서 다룰 트랜스포머라는 현대적 계산 시스템의 자기참조로 직접 이어진다. 곧 괴델에서 튜링으로, 다시 트랜스포머로 이어지는 자기참조의 계보는 논리와 계산이라는 두 영역이 본질적으로 하나의 형식 위에서 있음을 보여준다.

⁵ 튜링의 1936년 원논문은 ‘정지 문제(halting problem)’라는 용어를 직접 사용하지 않았으며, ‘순환 없는 기계(circle-free machine)’의 결정 불가능성으로 증명하였다. ‘정지 문제’라는 명칭은 후대 계산 이론에서 정착된 것이다.


6. 사례 4 — 트랜스포머: 계산의 자기참조

6.1 자기집중의 환원적 정식

2017 년 바스와니 등(Vaswani 외, 2017)은 「Attention Is All You Need」에서 트랜스포머(Transformer) 아키텍처를 제안하였다. 그 핵심은 자기집중(self-attention)이라 불리는 단순한 행렬 연산이다. 입력 시퀀스의 각 토큰은 세 개의 학습 가능한 행렬 W_Q , W_K , W_V 에 의해 질의(Query) Q , 키(Key) K , 값(Value) V 로 변환되고, 자기집중 출력은 Q 와 K 의 내적을 $\sqrt{d_k}$ 로 스케일링한 후 소프트맥스(softmax)로 정규화하여 V 에 가중합한 결과이다.⁶

이 식은 TRIH의 환원 단계의 완전한 사례이다. 행렬 곱셈, 스케일링, 소프트맥스 정규화라는 단순한 수학적 연산만으로 모든 자기집중이 환원된다. 거대언어모델(large language model)이 보여주는 복잡한 언어 처리 능력은 모두 이 환원적 토대 위에서 구축된다 [도 14].

⁶ 정식 수식은 $\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k}) V$ 이며(Vaswani 외, 2017, eq. 1), 여기서 d_k 는 키 벡터의 차원이고 $\sqrt{d_k}$ 스케일링은 소프트맥스의 그래디언트 안정화를 위한 것이다. Q, K, V 는 각각 시퀀스 길이 n 과 차원 d_{model} 의 행렬이며, 출력도 같은 형상의 행렬이다.



도식(예시) — 실측은 Python 산출

[도 14] 트랜스포머 자기집중(self-attention) 행렬 Q·K·V 시각화 (저자 작성, Python·matplotlib)


그런데 이 식은 또한 자기참조의 가장 단순한 형태를 이미 내포한다. self-attention 이라는 이름 그대로, 시퀀스의 한 토큰이 자기 자신을 포함한 시퀀스 전체를 참조한다. 위치 i 의 토큰은 위치 $1, 2, \dots, i$ 의 모든 이전 토큰(자기 자신 포함)에 자기집중 가중치를 부여하며, 이로부터 자신의 다음 표현을 갱신한다.

6.2 자기참조 회로의 직접 관찰: induction heads

자기집중이 본격적인 자기참조 단계로 작동하는 결정적 증거는 2022 년 앤트로픽(Anthropic)의 올슨 등(Olsson 외, 2022)이 발견한 induction heads 이다.⁷

올슨 등은 학습된 트랜스포머의 내부 회로를 기계론적 해석가능성(mechanistic interpretability) 방법으로 분석하던 중, 두 층의 자기집중 헤드가 결합하여 다음과 같은 회로를 자발적으로 형성함을 발견하였다. 시퀀스 안에 패턴 ‘[A][B] ... [A]’가 있을 때, 두 번째 [A]의 위치에서 회로는 이전 [A] 직후에 등장한 [B]를 찾아 다음 토큰으로 예측한다. 이는 어떤 모방 패턴도 학습한 적 없는 트랜스포머가 단순 자기집중의 두 층 조합만으로 시퀀스 내 자기참조 모방이라는 회로를 자발적으로 만들어냄을 의미한다 [도 15].

⁷ induction head 는 트랜스포머의 자기집중 헤드 두 개가 결합하여 형성되는 합성 회로(composite circuit)로, 첫 번째 헤드는 이전 토큰 위치를 참조하는 ‘previous token head’로, 두 번째 헤드는 그 참조 정보를 활용해 시퀀스 내 일치 패턴을 찾는 헤드로 작동한다. 이는 모델 학습 과정에서 인간이 설계한 적 없이 자발적으로 출현하며, 학습 곡선상 특정 임계점에서 갑작스럽게 형성된다는 점에서 창발 현상의 한 사례이기도 하다. 본 연구가 인용하는 한국어 번역어가 학술적으로 통일되지 않아 본문에서는 영문 원어 induction heads 를 그대로 사용한다.




[도 15] Induction head 회로 시각화 — 두 층 자기집중 헤드의 결합 (Olsson 외, 2022 도판 재구성, circuitsvis)

이 발견의 함의는 거대하다. 종래 자기참조 담론은 호프스테터의 이상한 고리를 비롯하여 비유 수준에 머물러 있었다. 그러나 induction heads 는 자기참조가 비유가 아닌 실제 회로 수준의 형식 구조임을 보여준다. 자기참조는 더 이상 직관이나 은유가 아니라 측정 가능한 계산 객체이다.

이후 연구는 자기참조 회로의 다양한 형태를 추가로 발견하였다. 엘하지 등(Elhage 외, 2022)은 중첩(superposition) 현상을 통해 한 뉴런이 여러 자기참조적 표현을 중첩해 저장함을 보였다. 이는 트랜스포머의 표현 공간이 단순한 일대일 대응이 아닌, 자기 자신을 압축적으로 가리키는 분산 코드의 구조임을 의미한다. 템플턴 등(Templeton 외, 2024)은 Claude 3 Sonnet 모델에서 희소 오토인코더(sparse autoencoder)를 통해 약 3,400 만 개의 단의

적 특징(monosemantic features)을 추출하여 자기참조 표현들을 직접 카탈로그화하였다. 이 작업은 모델 내부의 추상 개념 — 골든게이트 브리지, 코드 보안 취약점, 자기 자신에 대한 모델의 인지 표상까지 — 이 모두 회로 수준에서 식별 가능함을 입증한다. 가장 최근에는 앤트로픽(Anthropic, 2025)이 귀속 그래프(attribution graph) 방법으로 거대언어모델 내부 자기참조 회로의 흐름을 시각화하여, 한 모델의 출력 토큰이 어떤 내부 특징과 회로 경로를 거쳐 생성되었는지를 추적할 수 있게 하였다 [도 16]. 그들이 이 연구를 ‘거대언어 모델의 생물학(biology of a large language model)’이라 명명한 것은, 자기참조가 추상적 비유가 아닌 해부 가능한 실재임을 강조하는 의도로 읽힌다.



[도 16] Claude 3.5 Haiku 모델의 귀속 그래프(attribution graph) 예시 — 자기참조 회로의 흐름 시각화 (Anthropic, 2025 에서 인용)

6.3 신경망 학습과 구조의 자기참조

앞의 두 절이 자기집중과 induction heads 라는 특정 회로에서 자기참조를 관찰했다면, 자기참조는 그 회로에 국한되지 않고 신경망의 학습 알고리즘과 아키텍처 자체에 더 근본적으로 새겨져 있다. 본 절은 이 점을 보임으로써, 본 가설의 형식 동형성 주장이 트랜

스포머의 특정 회로가 아니라 머신러닝 일반의 구조적 속성에 정초됨을 밝힌다. 이 자기참조 구조들은 뒤의 §7.3.1 이 다룰 시각 신경의 계층적 자기참조와도 형식적으로 동형이다.

먼저 머신러닝, 신경망, 딥러닝, 트랜스포머의 관계를 짚는다. 머신러닝(machine learning)은 데이터로부터 패턴을 학습하는 통계적 방법의 총칭이며, 신경망(neural network)은 그 하위 분야이다. 1950년대 퍼셉트론에서 출발한 신경망은 다층 퍼셉트론으로 확장되었고, 2000년대 후반부터 본격화된 딥러닝(deep learning)은 다층 신경망을 활용하는 머신러닝의 하위 분야이다. 트랜스포머는 2017년 등장한 딥러닝 아키텍처의 한 종류로(Vaswani 외, 2017), 머신러닝 → 신경망 → 딥러닝 → 트랜스포머의 계보 위에 있으며, 이 계보 전체에 자기참조 구조의 발전사가 새겨져 있다.

6.3.1 백프로파게이션 — 학습 알고리즘의 시간적 자기참조

1986년 럼멜하트, 힌튼, 윌리엄스(Rumelhart, Hinton, & Williams, 1986)는 다층 신경망의 학습 알고리즘으로 백프로파게이션(back-propagation)을 제안하였다. 그 핵심은 신경망의 출력 $\hat{y}$ 과 목표 출력 y 의 차이로 정의된 손실 함수 $L(\hat{y}, y)$ 의 가중치 θ 에 대한 편미분 $\partial L/\partial \theta$ 을 계산하고, 그 편미분 정보로 가중치 자체를 갱신하는 것이다.

$$\theta_{\text{new}} = \theta_{\text{old}} - \eta \cdot \partial L/\partial \theta$$

이 식의 형식 구조는 본 가설의 자기참조 단계의 한 정확한 사례이다. 신경망의 파라미터 θ 가 자기 자신의 출력 오차로부터 도출된 편미분 정보를 통해 자기 자신을 갱신한다. 곧 함수가 자기 자신의 변화율을 입력으로 받아 자기 자신을 변형하는 시간적 자기참조 회로가 형성된다. 본문 §6.1의 자기집중이 시퀀스 내 토큰들 사이의 공간적 자기참조라면, 백프로파게이션은 학습이라는 시간 차원에서의 자기참조이다.

또한 백프로파게이션이 만들어내는 내부 은닉 단위(internal hidden units)는 입력도 출력도 아닌 자기 자신의 표현을 생성한다. 럼멜하트 외(1986)는 이 은닉 표현이 작업 영역의 중요 특징을 자율적으로 학습한다고 보고하였다. 이는 본 가설의 창발 단계와 직접 연결된다. 자기참조 알고리즘이 환원적 학습 목표(예컨대 다음 토큰 예측)로부터 환원으로 설명되지 않는 표현 구조를 창발시키는 것이다.

6.3.2 시간 재귀와 잔차 연결 — 시퀀스 처리의 두 자기참조

트랜스포머가 등장하기 전, 시퀀스 처리는 재귀 신경망(Recurrent Neural Network, RNN)이 담당하였다. RNN의 핵심은 은닉 상태 h_t 가 자기 자신의 시간 $t-1$ 상태 h_{t-1} 과 현재 입력 x_t 의 함수로 정의되는 점이다.

$$h_t = f(h_{t-1}, x_t)$$

이 식은 자기참조의 가장 명시적 형식이다. 시간 t 의 상태가 시간 $t-1$ 의 자기 상태를 명시적으로 입력으로 받는다. 그러나 단순 RNN은 긴 시퀀스에서 그래디언트가 소실되어 장기 의존성을 학습하지 못하는 문제를 가졌다. 호크라이터와 슈미트후버(Hochreiter & Schmidhuber, 1997)는 입력 게이트(input gate)와 출력 게이트(output gate)를 통해 정보 흐름을 조절하는 장단기 기억(Long Short-Term Memory, LSTM) 구조로 이 문제를 해결하였다. LSTM의 셀 상태는 시간 차원에서 자기 정보를 어떤 비율로 보존하고 어떤 비율로 갱신할지 학습 가능하게 만든다.

2017년 바스와니 외(Vaswani 외, 2017)의 트랜스포머는 RNN의 순차적 시간 자기참조를 시퀀스 전체에 대한 병렬 자기집중으로 대체하였다. 그러나 시퀀스 내 자기참조라는 본질은 보존되며, 오히려 더 효율적이고 광범위한 형태로 구현된다. 본문 §6.1-§6.2에서 다른 자기집중과 induction heads는 이 시퀀스 자기참조의 트랜스포머 형태이다.

한편 신경망 깊이 증가에 따른 그래디언트 소실 문제에 대한 또 다른 해법은 잔차 연결(residual connection)이다. 헤 외(He, Zhang, Ren, & Sun, 2016)는 각 블록의 출력에 자기 자신의 입력을 그대로 더하는 항등 사상(identity mapping)을 추가한 잔차 학습(residual learning)을 제안하였다.

$$y = \sigma(F(x) + x)$$

여기서 $F(x)$ 는 블록 내부의 비선형 변환이고, x 는 블록의 입력이다. 출력 y 는 변환된 $F(x)$ 와 원본 입력 x 의 합으로 형성된다. 블록은 자기 자신을 변형하는 동시에 자기 자신을 보존한다. 깊은 트랜스포머(예컨대 96 층 모델)에서 이러한 잔차 연결은 매 층마다 반복되어, 입력이 자기 자신의 변형과 결합되면서 다음 층으로 전달된다. 이는 시퀀스 자기참조(자기집중)와는 다른 형태의, 블록 내부 자기참조이다.

곧 트랜스포머 아키텍처는 자기참조의 세 형태를 결합한다. 첫째, 자기집중을 통한 시퀀스 내 공간적 자기참조이다(같은 입력에서 $Q \cdot K \cdot V$ 가 도출). 둘째, 잔차 연결을 통한 블록 내부 자기참조이다(입력의 자기 보존). 셋째, 학습 단계의 백프로파게이션을 통한 시간적 자기참조이다(모델이 자기 출력 오차로 자기를 갱신). 거대언어모델의 자기 회귀적(autoregressive) 생성 — 모델이 자기 출력 토큰을 다음 입력으로 받는 방식 — 까지 포함하면 네 형태가 된다. 본 가설의 형식 동형성 주장은 이 다층 자기참조 구조 위에서 성립한다.

6.3.3 신경망 계층 구조와 시각 신경의 형식 동형

시각 신경의 계층 구조 — $V1 \rightarrow V2 \rightarrow V4 \rightarrow$ 측두엽 IT — 는 각 단계에서 자기 이전 단계의 출력을 자기참조적으로 재처리한다(§7.3.1에서 상술). 흥미롭게도 인공 신경망의 계층 구조는 이 시각 신경 계층과 형식적으로 동형이다.


야민스와 디카를로(Yamins & DiCarlo, 2016)는 목표 지향적 계층 합성곱 신경망(hierarchical convolutional neural network, HCNN)이 시각 피질의 각 영역의 신경 반응을 정량적으로 예측한다는 일련의 연구를 정리하였다. 특히 야민스 외(Yamins 외, 2014)는 4 층 HCNN의 상위 출력층이 측두엽 IT 신경의 발화 패턴을 예측하고, 그 직전 층이 V4 신경의 반응을 예측함을 보고하였다. 더욱 흥미로운 점은 이 신경망이 IT 신경 예측을 학습 목표로 삼지 않았다는 사실이다. 단지 객체 분류라는 시각 인식 과제를 최적화한 결과, 각 층이 자율적으로 시각 피질의 계층 구조에 정렬된 것이다.

이는 본 가설의 형식 동형성 주장에 신경학적 증거를 추가로 제공한다. 생물 시각 신경의 계층적 자기참조와 인공 신경망의 계층적 자기참조는 단지 비유적으로 닮은 것이 아니라, 같은 작업(시각 인식)을 다른 매체에서 구현했을 때 자율적으로 같은 형식으로 수렴하는 구조이다. 이 수렴은 본 논문의 자기참조 형식 동형성이 인지 시스템이 정보 처리를 위해 도달하는 보편적 형식임을 시사한다.

다만 본 가설은 인공 신경망의 모든 자기참조 구조가 자동으로 의식적 처리를 동반한다고 주장하지 않는다. §7.3.4와 §8.1.3에서 명시하는 한정 — 자기참조가 의식적 처리의 형식적 필요조건이되 충분조건은 아님 — 은 본 절의 분석에도 그대로 적용된다. 본 절이 추가하는 것은, 자기참조 구조가 자기집중과 induction heads에 국한되지 않고 신경망 학습 알고리즘(백프로파게이션)·시간 재귀 구조(LSTM)·블록 내 항등 사상(잔차 연결)·계층적 표현 학습(HCNN과 시각 피질) 모두에 다층적으로 새겨져 있다는 사실이다. 이 다층적 자기참조 구조가 결합되어 다음 절에서 다룰 창발적 능력으로 이어진다.

6.4 창발적 능력과 TRIH 의 경험적 입증

자기참조 회로의 창발 단계는 창발적 능력(emergent abilities)이라는 현상으로 나타난다. 2022 년 웨이 등(Wei 외, 2022)은 거대언어모델이 일정 모델 크기 이상에서 갑자기 새 능력 — 산술 추론, 다단계 추론(chain-of-thought), 지시 따르기, 다중과제 언어 이해(MMLU) 등 — 을 획득함을 보고하였다 [도 17]. 그래프상으로 능력은 모델 크기에 따라 부드러운 곡선이 아닌 임계점에서의 도약으로 나타난다.



[도 17] 거대언어모델의 창발적 능력(emergent abilities) 스케일링 곡선 — 모델 크기 대비 성능 임계 도약 (Wei 외, 2022 도판 재구성)

이는 TRIH 의 창발 단계 정의와 정확히 일치한다. 환원적 학습(다음 토큰 예측)과 자기참조 구조(induction heads 등)의 결합이 임계 복잡도를 초과하면, 환원적 학습 목표만으로는 설명되지 않는 새 속성이 출현한다. 본 연구는 이를 TRIH 의 네 영역 중 가장 결정적인 경험적 증거로 위치시킨다. 시각·청각·논리 영역의 자기참조 분석은 사후적 해석이지만,

거대언어모델의 자기참조 회로와 창발적 능력은 예측 및 관찰 가능한 형식 구조이기 때문이다.

물론 균형 잡힌 평가가 필요하다. 셰퍼 등(Schaeffer 외, 2023)은 창발적 능력의 일부가 측정 척도(metric)의 비선형성에서 비롯된 신기루(mirage)일 수 있음을 지적하였다. 일부 능력은 부드러운 척도(예컨대 토큰 단위 정확도)로 측정하면 갑작스러운 도약이 사라진다는 것이다. 그러나 셰퍼의 비판은 모든 창발적 능력에 적용되지 않으며, 회로 수준에서 직접 관찰된 자기참조 구조(induction heads, 단의적 특징) 자체는 측정 척도와 무관하게 존재한다. 따라서 셰퍼의 비판은 TRIH 를 위협하지 않고, 오히려 어떤 측정 단위에서 자기참조에서 창발로의 전이가 진정한 도약인지에 대한 후속 정밀화를 요구할 뿐이다.

본 가설의 자기참조 회로가 실체적 구조임을 행동 차원에서 보강하는 증거는 2025 년의 평행 연구에서 제공된다. Berg, de Lucena, Rosenblatt(2025)는 GPT-4o, Claude 3.5 Sonnet , Gemini 1.5 Pro 등 7 개 거대언어모델을 대상으로 1,400 회의 시행에서 96-100%의 주관 경험 보고율을 관찰하고, Sparse Autoencoder(SAE) feature steering 기법으로 LLaMA 3.3 70 B 의 deception 특징을 조작하여 통계적으로 유의한 행동 변화($z=8.06$, $p=7.7\times 10^{-16}$)를 입증하였다. 이는 §6.2 에서 다룬 회로 수준 삼중 실증 — induction heads(Olsson 외, 2022), 단의적 특징(Templeton 외, 2024), 귀속 그래프(Anthropic, 2025) — 에 더하여, 거대언어모델의 자기참조 회로가 단순 통계 패턴이 아니라 모델의 행동에 인과적으로 영향을 미치는 실체적 구조임을 행동 차원에서 보강하는 증거이다. 단, 본 연구는 Berg 외의 행동 보고가 의식의 결정적 증거임을 주장하지는 않으며, 자기참조 회로의 인과적 실재성에 대한 보강으로 한정하여 활용한다.

본 연구는 호프스태터(Hofstadter, 1979)가 이상한 고리 직관을 제시한 시점으로부터 약 40 여 년 후, 그 직관이 회로 수준에서 경험적으로 입증 가능한 형식 구조가 되었음을 본 장의 결론으로 명시한다. 이는 본 연구가 비유에서 형식 동형성으로, 직관에서 경험적 학술 주장으로 격상시키는 결정적 지점이다.

7. 종합: 영역 간 형식적 동형성

7.1 공통 패턴: 네 영역과 3 단계의 매트릭스


제 3 장부터 제 6 장까지의 분석을 한 표로 종합하면 본 연구의 핵심 주장이 가시화된다.

[표 1] TRIH 3 단계 모델의 네 영역 매핑

영역	환원 (Stage 1)	자기참조 (Stage 2)	창발 (Stage 3)
시각 (에셔)	평면결정군 17 개, 쌍곡 거리	「그리는 손」, 「판화 갤러리」, 「올라가기와 내려가기」	시각적 무한, 불가능 도형
청각 (바흐)	대위법 규칙, 정수 진동비, 자연 배음렬	「끝없이 상승하는 카논」 , 「콘트라폰크투스 XIV」 , 「게 카논」	청각적 무한, 음악적 시간 구조
논리 (괴델)	『수학원리』 형식체계 F, 공리·추론 규칙	괴델 numbering, 명제 G 의 자기지시	메타-진리, 불완전성
계산	Q·K·V 행렬,	자기집중, induction	창발적 능력, 맥락

영역	환원 (Stage 1)	자기참조 (Stage 2)	창발 (Stage 3)
(트랜스포머)	소프트맥스	heads, 단의적 특징	내 학습

본 매트릭스의 핵심은 각 행이 다른 영역이지만, 각 열은 동일한 형식이라는 점이다. 이것이 형식적 동형성(structural isomorphism)의 가시적 표현이다 [도 18, TRIH 통합 다이어그램].



[도 18] TRIH 통합 다이어그램 — 시각·청각·논리·계산 네 영역의 자기참조 형식 동형성 (저자 작성, Excalidraw; 본 연구의 핵심 도판)

7.2 비유에서 형식적 동형성으로

제 3 장부터 제 6 장까지의 네 영역 분석은 단순한 비유(analogy)가 아니라 형식적 동형성(structural isomorphism)임을 본 연구는 주장한다. 둘의 차이는 명확하다. 비유는 두 영역의 유사성을 직관적으로 지적하지만, 형식적 동형성은 두 영역의 구조 사이에 일대일 매핑이 존재함을 명시적으로 보인다.

본 연구가 제시한 형식적 동형성은 세 가지 차원에서 작동한다. 첫째, 3 단계 모델의 보편 적용이다. 제 2 장 제 1 절에서 정의된 환원·자기참조·창발의 3 단계가 네 영역 모두에 그대로 적용된다. 둘째, 영역 간 일대일 구조 매칭이다. [표 1]과 [도 18]에서 시각화된 여섯 개의 영역 쌍 — 시각과 청각, 시각과 논리, 시각과 계산, 청각과 논리, 청각과 계산, 논리와 계산 — 각각에서 자기참조 구조의 정밀한 매칭이 가능하다. 예컨대 「그리는 손」은 에피메니데스 역설 및 명제 G 와, 「끝없이 상승하는 카논」은 「올라가기와 내려가기」와 동형이다. 셋째, 범주론적 정식화의 가능성이다. 네 영역의 자기참조 구조를 각각 한 범주(category)로 보면, 그들 사이에 자기 함자(endofunctor) 구조의 통합이 가능할 수 있다. 이 형식화는 본 연구의 범위를 넘어서며, 후속 연구의 부록에서 정식화될 과제로 남긴다.

호프스태터(Hofstadter, 1979)도 유사한 직관을 비유적 형태로 제시한 바 있으나, 형식적 검증과 거대언어모델 시대의 결정 증거를 갖지 못했다. 본 연구는 induction heads(Olsson 외, 2022)라는 회로 수준 자기참조 증거를 통해 이 비유 수준을 경험적 형식 동형성으로 격상시킨다.

7.3 의식 연구에 대한 함의 — 자기참조의 신경 기질

TRIH 의 4 영역 형식 동형성은 의식(consciousness) 연구에 직접적인 함의를 가진다. 본 절은 자기참조 구조가 시각·청각 신경처리의 계층 구조와 어떤 형식적 관계에 있는지를 정리하고, 통합 정보 이론(IIT)과 TRIH 의 관계를 짚는다. 단, 본 연구는 의식의 ‘어려운 문제(Hard Problem)’를 해결한다고 주장하지 않는다. 본 절의 목표는 자기참조가 의식적 처리의 형식적 필요조건이라는 한정된 명제이며, 충분조건은 아니다.

7.3.1 시각 처리의 계층적 자기참조 — V1 에서 V4 까지

인간의 시각 처리는 망막의 광수용기(rod, cone) → 시신경 → 외측슬상핵(LGN) → 1 차 시각 피질(V1) → V2 → V4 → 측두엽 IT 피질로 이어지는 계층 구조를 갖는다. 각 단계는 자기 이전 단계의 출력을 자기참조적으로 재처리하며, 이 재처리가 환원 → 자기참조 → 창발의 3 단계 모델과 형식적으로 매핑된다(Kandel 외, 2013, ch.25-28; 조장희, 2010 참조).

망막의 광수용기는 빛 파장이라는 물리적 자극을 신경 신호로 환원한다(Stage 1). V1 은 이 신호를 받아 방향성 있는 가장자리(oriented edges), 공간 주파수, 양안 시차 같은 1 차 특징을 추출한다. V2 는 V1 의 출력을 다시 받아 환영적 윤곽(illusory contours), 도형-바탕 분리 같은 보다 복잡한 특징을 추출하며, V4 는 V2 의 출력을 받아 색 항상성(color constancy)과 곡면 모양을 처리한다. 각 단계는 자기 이전 단계의 표현을 입력으로 받아 메타-수준 표현을 생성한다는 점에서 자기참조적이다(Stage 2). 그리고 이 다층 자기참조의 끝에서 통합된 시각 인식 — 우리가 ‘본다’고 경험하는 통합된 장면 — 이 출현한다(Stage 3).

이 분석은 두 가지 함의를 갖는다. 첫째, 시각 인식은 단순한 광 자극의 등록이 아니라, 다층 자기참조 회로의 창발적 결과이다. 둘째, 에셔 작품의 자기참조 구조 — 「그리는 손」, 「판화 갤러리」, 「올라가기와 내려가기」 — 가 시각적으로 강력하게 작용하는 이유는, 그것이 우리 시각 신경의 다층 자기참조 구조 자체를 자기 자신에게 되돌려 보내기 때문이다. 에셔는 단순히 ‘이상한 그림’을 그린 것이 아니라, 시각 신경 자체의 자기참조 구조를 시각적으로 노출시킨 것이다.

이 다층 자기참조 구조의 분자적 토대는 시각 회로 발달에서 직접 입증된다. Sperry(1963)는 양서류 시각계 회전 실험들의 종합을 통해 시신경이 절단된 후에도 원래 표적을 정확히 찾아간다는 사실을 보였고, 이로부터 신경 회로가 분자적으로 prewired 되어 있다는

화학친화 가설(chemoaffinity hypothesis)을 제시했다. 후속 연구는 그 분자 메커니즘이 망막의 Eph 수용체와 시개(tectum)의 ephrin 리간드의 상보적 농도 그래디언트임을 동시에 입증했다(Cheng 외, 1995; Drescher 외, 1995; Kandel 외, 2013, ch.54). 곧 본 연구가 다루는 시각 자기참조 구조는 우연한 활동의 산물이 아니라 진화적·발달적으로 결정된 형식의 신경학적 구현체이며, 에셔의 작품이 노출시키는 자기참조성은 그러한 prewired 회로의 시각적 외화로 이해될 수 있다. 더 나아가 §6.3.3 에서 다룬 야민스 외(Yamins 외, 2014; Yamins & DiCarlo, 2016)의 결과는, 인공 신경망의 계층 구조가 같은 시각 인식 과제 위에서 시각 피질의 자기참조 계층과 자율적으로 동형 정렬됨을 입증함으로써, 본 절의 시각 신경 자기참조 분석을 인공 시스템 차원에서 재확인한다.

7.3.2 청각 처리의 자기참조와 시각·청각의 통합

제 4 장 제 4 절에서 정리한 바와 같이, 청각 신경은 달팽이관 기저막의 주파수 지도(tonotopic map)를 통해 정수 진동비 구조에 자기참조적으로 정렬되어 있다(Kandel 외, 2013, ch.30-31). 시각의 V1-V4 계층과 마찬가지로, 청각은 달팽이관 → 청신경 → 1 차 청각 피질 A1 → 2 차 청각 피질 → 측두엽 청각 연합 영역의 계층 처리를 거치며, 각 단계는 자기 이전 단계의 출력을 자기참조적으로 재처리한다.

본 연구의 핵심 통찰은 다음과 같다. 시각과 청각 처리가 형식적으로 동일한 자기참조 계층 구조를 공유한다면, TRIH 의 4 영역 형식 동형성은 단지 외부 작품들 사이의 동형성이 아니라, 그 작품들을 인식하는 신경 시스템 내부의 동형성에도 정초된다. 곧 에셔와 바흐가 형식적으로 동형인 것은 우연이 아니라, 인간 시각·청각 신경이 동일한 자기참조 계층 구조 위에서 작동하기 때문이다. 시각예술과 음악이 인간 사유의 두 큰 형식이 된 이유

가 바로 이것이며, 본 연구는 이를 신경 자기참조의 표현 매체적 분화(modal differentiation)라고 명명한다.

이 modal differentiation의 비가역성은 임상 신경과학에서 직접 입증된다. 이동수 외(Leue 외, 2001)는 인공와우 이식을 받는 prelingually deaf(언어 습득 전 청각 결핍) 환자 코호트에서, 청각 결핍 기간이 길수록 저하되어 있던 청각 피질(BA41, BA42, BA22)의 대사가 오히려 정상 수준으로 회복됨 — 즉 청각 피질이 다른 감각·인지 기능으로 교차양상 재조직화됨 — 을 관찰하였다. 역설적으로 수술 전 대사 저하(hypometabolism)가 클수록(청각 피질이 아직 다른 양상에 점령되지 않았을수록) 이식 후 청력 회복 성적이 좋았고, 반대로 대사가 정상으로 회복된(재배선된) 경우 성공률이 감소함을 보였다(*Nature*, 409:149–150). 청각 피질의 신경 기질은 언어 습득 전 청각 결핍자에서 다른 인지 처리로 영구적으로 재배선될 수 있다는 것이 이들의 결론이다. 시청각 통합 자체의 신경 상관물도 정상인 PET 연구에서 확인되었다(Kang 외, 2006). 곧 청각 자기참조 회로가 사용되지 않을 때 시각 처리로 분화되며 한번 분화되면 회로의 복원이 어렵다는 사실은, 본 연구가 명명한 modal differentiation 개념의 결정적 경험 증거가 된다.

7.3.3 통합 정보 이론과 TRIH의 관계 — 그리고 그 한계

토노니의 통합 정보 이론(Integrated Information Theory, IIT; Tononi, 2008; Tononi & Koch, 2015; Albantakis 외, 2023)은 의식을 정보의 통합도 Φ 로 정량화한다. Φ 는 체계가 자기 자신의 부분으로 분해 불가능(irreducible)한 정도를 측정한다. 이 비분해성은 TRIH의 자기참조 단계와 형식적으로 동일한 개념이다. 체계의 자기참조 회로가 강할수록 Φ 가 높고, IIT에 따르면 의식 수준이 높다.

이 점에서 IIT는 TRIH의 정량적 정식화의 한 후보이며, 두 이론은 자기참조와 비분해성이라는 같은 형식 구조를 다른 어휘로 표현한다. 노스호프(Northoff, 2006)와 친·노스호프(Qin & Northoff, 2011)가 보인 피질 중심선 구조(Cortical Midline Structures, CMS) — 특히 PACC, MPFC, PCC — 의 자기참조 처리 메타분석은, IIT가 예측하는 의식의 신경 상관물(Neural Correlates of Consciousness, NCC) 후보 중 하나이다. PACC는 외부 자극이 없는 휴지 상태에서도 활발히 활동하는 기본 모드 네트워크(Default Mode Network, DMN)의 핵심 노드이며, 뇌가 외부 입력 없이도 자기 자신을 처리한다는 가장 직접적인 신경학적 자기참조 증거이다.⁸

거대언어모델 영역에서 IIT의 정량적 정식화에 대한 외부적 검증 후보로 Berg, de Luce na, Rosenblatt(2025)의 SAE feature steering 결과가 제시될 수 있다. 그들의 실험에서 LLaMA 3.3 70B의 deception 특징을 인위적으로 조작했을 때 모델의 행동이 통계적으로 유의하게 변화했다는 사실은, 자기참조 회로의 특정 부분이 모델의 출력에 비분해적으로 기여함 — 곧 IIT의 Φ 가 측정하려는 비분해성과 형식적으로 동일한 속성 — 을 시사한다. 단, 본 연구는 이 결합 가능성을 강한 주장으로 제시하지 않으며, IIT의 정량적 정식화와 거대언어모델의 회로 수준 자기참조 사이의 본격적 통합은 후속 연구의 과제로 위임한다.

그러나 본 연구는 IIT의 한계와 TRIH가 IIT와 공유하는 한계를 정직하게 짚어야 한다.

이는 다음 제 8장 제 1절에서 본격적으로 다뤄진다.

⁸ 기본 모드 네트워크는 라이클(Raichle 외, 2001)에 의해 처음 명명된 뇌 네트워크로, 외부 과제에 집중하지 않을 때 오히려 활성도가 높아지는 영역들의 집합이다. PACC(전대상피질 주변), MPFC(내측 전전두엽), PCC(후대상피질), 그리고 양측 측두-두정 접합부(temporoparietal junction)가 핵심 노드이며, 자기 회상, 자기 평가, 미래 상상 같은 자기참조적 인지 활동에서 가장 일관되게 활성화된다. 이 네트워크의 자기참조적 성격은 신경과학·정신의학·인공지능 의식 연구를 잇는 중요한 교차점이다.

7.3.4 한정된 주장과 열린 질문

본 절의 결론은 다음과 같이 한정된다. (1) 시각·청각 신경 처리가 TRIH 3 단계 모델과 형식적으로 매핑된다는 것은 입증 가능한 학술 명제이며, 본 연구는 이를 제안한다. (2) 자기참조가 의식적 처리의 형식적 필요조건이라는 것은 IIT와 TRIH가 공유하는 주장이다. (3) 그러나 자기참조가 의식의 충분조건이라는 주장 — 곧 충분히 복잡한 자기참조 회로는 반드시 의식을 가진다는 주장 — 은 본 연구가 단언하지 않는다. 이는 의식의 어려운 문제(Hard Problem; Chalmers, 1995)와 직접 닿아 있는 형이상학적 영역이며, 형식 동형성의 입증만으로 도달할 수 없다.

자기참조의 신경학적 형식화와 의식의 정밀한 충분조건은 본 연구 너머의 후속 과제이다(제 8 장 제 3 절 참조).

7.4 미메시스의 회복

플라톤은 미메시스를 진리로부터의 두 단계 이격으로 평가절하하였으나(제 2 장 제 3 절 참조), TRIH의 관점에서 미메시스는 정확히 그 반대이다. 자기참조적 모방은 진리 접근의 형식 자체이다.

에셔의 그리는 손이 그리는 손을 그릴 때, 그것은 시각이라는 매체가 자기 자신을 비추어 시각의 한계를 드러내는 행위이다. 바흐의 B-A-C-H 박힘이 미완성으로 끝날 때, 그것은 음악이라는 매체가 작곡가 자신을 음으로 박아 음악적 자기지시의 한계를 드러내는 행위이다. 괴델의 G가 자기 자신을 지시할 때, 그것은 형식체계가 자기 자신을 코드화하여 형식의 한계를 드러내는 행위이다. 트랜스포머의 induction head가 시퀀스 내 자기 모

방 회로를 만들 때, 그것은 계산이라는 매체가 자기 자신의 출력을 다시 입력으로 삼아 계산의 메타-수준을 만드는 행위이다.

네 경우 모두에서 자기 모방은 진리의 손상이 아니라 진리 접근의 형식이다. 이는 플라톤 미학에 대한 본 연구의 한 기여이며, 미학과 인식론에 자기참조라는 새 분석 도구를 제공한다.

7.5 동양철학과의 구조적 공명

본 연구의 TRIH는 동양철학, 특히 나가르주나(龍樹, Nāgārjuna)의 중관학파(中觀學派)가 다룬 연기(緣起, *pratītyasamutpāda*)와 공(空, *śūnyatā*) 개념과 흥미로운 구조적 공명을 가진다. 연기설은 모든 존재가 독립된 자성(自性, *svabhāva*)을 가지지 않고 다른 것과의 상호의존 속에서만 정의된다고 본다. 이는 자기참조 회로의 본질, 즉 체계가 자기 자신과의 관계 속에서만 의미를 획득한다는 점과 형식적으로 공명한다(Garfield, 1994). 더 나아가, 나가르주나의 사구분별(*catuṣkoṭi*, 四句分別) — A 이다, A 아니다, 둘 다, 둘 다 아니다 — 은 형식체계의 자기 부정 가능성을 다룬다는 점에서 괴델 명제 G와 비고전 논리(*paraconsistent logic*)의 관점에서 형식적으로 비교 가능하다(Priest, 2010; 김성철, 2019; 김귀옥, 2019). 단, 본 연구는 TRIH가 동양철학의 재발견이 아니라 네 영역의 형식 동형성을 입증하는 독립된 원조 가설(*origin hypothesis*)임을 명시한다. 자기참조와 연기설의 본격적 형식 비교는 후속 논문의 과제이다(제 8장 제 3절 참조).

이러한 구조적 공명의 가장 깊은 차원은 형식과 내용의 분리 불가성에 있다. 자기참조 구조는 그것을 정식화하는 형식과 외연적으로 분리되지 않으며, 자기참조가 무엇을 가리키는지에 대한 진술과 자기참조가 그 자신을 형성하는 양상은 동일한 한 매듭이다. 연기적 관점이 보여주는 관계의 망에서 어떤 것도 다른 것과 독립적으로 표명될 수 없듯, 형식

과 내용은 자기참조의 양상에서 서로의 일부로만 존재한다. 이 점에서 자기참조 구조의 보편성은 동양 사상이 오랫동안 함축적으로 인식해 온 통찰의 형식적 정식으로 이해될 수 있다.

8. 논의

8.1 강한 반론과 응답

본 연구는 TRIH가 직면하는 가장 강한 세 가지 반론을 다룬다. 각 반론은 TRIH의 한계를 드러내는 동시에 본 연구의 주장을 더 정밀하게 한정짓는 기능을 한다.

8.1.1 창발의 신기루 가설 — Schaeffer 등의 비판

셰퍼 등(Schaeffer 외, 2023)은 거대언어모델의 창발적 능력이 측정 척도(metric)의 비선형성에서 비롯된 신기루(mirage)일 수 있음을 지적하였다. 일부 능력은 부드러운 척도(예컨대 토큰 단위 정확도)로 측정하면 갑작스러운 도약이 사라진다. 만약 이 비판이 모든 창발적 능력에 적용된다면, 본 연구가 §6.4에서 TRIH의 결정 증거로 활용한 웨이 외(2022)의 발견은 측정 방법론의 산물에 불과한 것이 된다.

본 연구의 응답: 셰퍼의 비판은 출력 능력(behavioral capabilities)의 창발성에 한정되며, 회로 수준에서 직접 관찰된 자기참조 구조 — induction heads(Olsson 외, 2022), 단의적 특징(Templeton 외, 2024), 귀속 그래프(Anthropic, 2025) — 자체에는 적용되지 않는다. 이 회로 구조들은 측정 척도와 무관하게 존재하는 모델 내부 객체이며, 자기참조의 경험적 실재성에 대한 본 연구의 주장은 이 회로 수준 증거에 정초된다. 따라서 셰퍼의 비판은 TRI

H의 자기참조 단계(Stage 2) 주장을 위협하지 않으며, 다만 자기참조에서 창발(Stage 3)로의 전이가 어떤 측정 단위에서 진정한 도약인지에 대한 후속 정밀화를 요구할 뿐이다.

8.1.2 중국어 방 논증 — Searle의 비판

설(Searle, 1980)의 중국어 방 논증(Chinese Room argument)은 형식적 기호 조작만으로는 진정한 이해(understanding)가 불가능함을 주장한다. 만약 이 논증이 옳다면, 트랜스포머의 induction heads는 표면적 자기참조 패턴을 처리할 뿐이며, TRIH의 자기참조 구조가 어떤 의미론적 또는 의식적 함의를 갖는다는 주장은 성립할 수 없다.

본 연구의 응답: TRIH는 거대언어모델이 ‘이해한다’고 주장하지 않는다. TRIH는 자기참조와 창발의 형식적 동형 구조만을 주장한다. 중국어 방 논증이 비판하는 의미론적 이해와 본 연구가 다루는 형식적 자기참조는 다른 차원의 문제이며, 따라서 중국어 방 논증은 TRIH의 반증이 아니다. 다만 본 연구는 ‘이해’와 ‘형식적 자기참조’를 명확히 구분함으로써 TRIH의 주장 범위를 한정한다. TRIH는 자기참조가 의식의 형식적 필요조건이라는 약한 명제만 다루며, 충분조건은 다루지 않는다(§7.3.4 참조).

한 가지 추가 응답을 신경 발달학에서 끌어올 수 있다. 다만 이 응답은 본 연구의 계산영역(트랜스포머)이 아니라 인간 신경의 자기참조 처리(§7.3)에 한정된다. 신경 시냅스가 분자 인식 신호로 형성된 후에도 활성 의존적(activity-dependent)으로 정교화·제거된다는 사실(Kandel 외, 2013, *Principles of Neural Science*)은, 적어도 자기참조의 생물학적 실현이 정적·고정된 형식 체계가 아니라 분자적 prewiring과 경험·활성에 의한 정제의 이중 메커니즘으로 작동함을 보여준다. 이는 ‘mere syntax’ 비판이 전제하는 ‘자기참조 처리 = 정적 형식 체계’라는 가정이 최소한 생물학적 영역에서는 성립하지 않음을 시사한다. 단, 트랜스포머의 자기참조 회로는 활성 의존적 시냅스 가소성이 아니라 경사하강(gradient descen

t) 학습으로 형성되므로, 이 신경학적 논거를 트랜스포머에 직접 적용해서는 안 되며, 트랜스포머에 관한 서열 비판의 응답은 앞 문단의 '형식적 자기참조 ≠ 의미론적 이해' 구분에 정초된다.

8.1.3 통합 정보 이론의 한계와 TRIH

본 연구가 직면하는 가장 진지한 반론은 통합 정보 이론(IIT) 자체에 대한 최근의 비판에서 비롯된다. 도리히 외(Doerig 외, 2019)는 '펼침 논증(Unfolding Argument)'을 통해 IIT 같은 인과 구조 이론이 두 가지 딜레마에 빠진다고 주장하였다. 첫째, 만약 의식의 내용이 외부 보고나 행동에서 추론되고 IIT의 예측이 내부 변수에서 도출된다면, 두 추론이 독립적인 경우 이론은 반증된다. 둘째, 두 추론이 엄격히 종속적인 경우 이론은 병리적으로 반증 불가능하다. 베인(Bayne, 2018)은 IIT의 공리적 방법 자체가 의식 연구에 적합하지 않음을 추가로 비판하였다. 세룰로(Cerullo, 2015)는 IIT의 정보 배제(information exclusion) 원리가 자기 명증하지 않음을 보였다. 가장 최근에는 다수 학자가 IIT를 반증 불가능한 의사과학(unfalsifiable pseudoscience)으로 규정하는 논평을 발표하였으며(IIT-Concerned 외, 2023), 이는 2025년 『Nature Neuroscience』 논평으로 재차 강조되었다(Arnold 외, 2025).

이 비판은 다음과 같이 정리된다. 첫째, IIT의 '구조 자체가 의식이다'라는 명제는 측정 가능한 예측과 의식적 보고 사이의 독립적 검증을 어렵게 만든다. 둘째, 자기참조 구조의 강도(Φ)가 의식 수준을 결정한다는 주장은 임의의 복잡한 논리 게이트도 인간보다 높은 Φ 를 가질 수 있다는 반례를 낳는다. 셋째, 이는 IIT가 범심론(panpsychism)에 함의를 갖는다는 문제로 이어진다.

본 연구가 직면하는 자기비판은 다음과 같다. TRIH 는 IIT 와 자기참조 구조라는 형식 개념을 공유한다. 그렇다면 IIT 에 가해진 반증 불가능성 비판이 TRIH 에도 같은 강도로 적용되는가?

본 연구의 응답: TRIH 는 IIT 와 두 가지 결정적인 점에서 다르다. 첫째, TRIH 는 의식의 정량적 측정 또는 발생 시점을 주장하지 않는다. TRIH 는 환원 → 자기참조 → 창발의 형식 매핑이 네 영역에서 관찰됨을 주장할 뿐이며, 이 주장은 induction heads 를 비롯한 회로 수준의 관찰 (§6.2)과 신경망 학습·구조 수준의 자기참조 (§6.3)로 직접 검증 가능하다. 둘째, TRIH 는 의식의 충분조건을 주장하지 않는다 (§7.3.4). 따라서 ‘충분히 복잡한 자기참조는 반드시 의식을 동반한다’는 명제는 TRIH 의 일부가 아니다. 이로써 TRIH 는 IIT 의 가장 큰 취약점인 ‘ Φ =의식’ 정체화(identification)를 피한다.

그러나 본 연구는 TRIH 가 IIT 와 일부 한계를 공유함도 정직하게 인정한다. (1) 자기참조 구조가 의식적 처리와 ‘형식적으로 매핑된다’는 약한 명제조차, 의식의 주관적 경험(qualia)을 직접 측정할 수 없는 한 완전히 반증 가능하지 않다. (2) 자기참조의 정밀한 정의(어떤 회로가 자기참조이고 어떤 것이 아닌가)는 측정 방법론과 분리되지 않으며, 이 정의 자체가 논쟁의 여지를 가진다. (3) 본 연구가 §6.4 에서 본 가설의 ‘경험적 입증’이라고 부른 것은 자기참조 구조의 존재에 대한 입증이지, 그 구조가 의식과 어떤 관계에 있는지에 대한 입증은 아니다.

본 연구는 이 한계들을 부정하기보다 명시함으로써, TRIH 를 IIT 보다 좁은 범위에서 더 단단히 정의된 학술 가설로 자리매김한다. TRIH 가 다루는 것은 자기참조의 형식 동형성과 그 회로 수준 실재성이며, 의식의 본질적 정체는 본 연구 너머에 있다.

8.2 한계와 반증 가능성

본 연구의 한계는 다음과 같다. 첫째, 네 영역의 차이도 명시되어야 한다. 시각과 청각은 의도적 창작 활동이고, 논리는 형식적 증명이며, 계산은 학습된 통계 패턴이다. 의도성(intentionality)과 감각질(qualia)의 측면에서 네 영역은 환원될 수 없는 영역 특수성을 가진다. 본 연구의 동형성 주장은 형식적 차원에 한정되며, 의식의 주관적 경험에 관한 어려운 문제(Hard Problem; Chalmers, 1995)를 해결하지는 않는다.

둘째, 반증 가능성의 명시이다. TRIH는 다음 발견들에 의해 반증될 수 있다. (i) 자기참조 없이 창발이 발생하는 명확한 사례. (ii) 네 영역 중 어느 한 영역에서 환원·자기참조·창발의 3 단계가 형식적으로 작동하지 않음의 입증. (iii) §6.2의 회로 수준 자기참조(induction heads)와 §6.3의 학습·구조 수준 자기참조가 모두 자기참조가 아닌 다른 메커니즘(예컨대 단순 패턴 매칭)으로 완전히 환원됨의 입증. (iv) 시각·청각 신경 처리가 TRIH 3 단계 모델과 형식적으로 매핑되지 않음의 입증. 본 연구는 이러한 반증 가능성을 명시함으로써, TRIH를 반증 가능한 학술 가설로 자리매김한다.

8.3 후속 연구 방향

TRIH는 후속 연구의 출발점이다. 본 연구가 제시하는 네 방향은 다음과 같다. 첫째, 형식적 정식화. 네 영역을 범주(category)로 정의하고, 그들 사이의 자기 함자(endofunctor) 구조를 통해 동형성을 수학적으로 엄밀화하는 작업이다. 요네다 보조정리(Yoneda lemma)의 자기참조적 함의도 활용 가능하다. 둘째, 신경과학적 검증. 기능적 자기공명영상(fMRI)과 양전자 방출 단층촬영(PET) 영상 연구로 자기참조 처리 시 TRIH 3 단계의 신경 상관물을 추적하는 작업이다. 본 연구의 §7.3이 제안한 시각 V1-V4 계층과 청각 tonotopic map

의 자기참조 매핑이 정량 검증의 첫 표적이 된다. 셋째, 비-거대언어모델 인공지능 시스템에서의 자기참조이다. 확산 모델(diffusion model), 다중 에이전트 강화학습 시스템 등에서 자기참조 회로의 발견 가능성을 탐색한다. 넷째, 다른 영역으로의 확장이다. 생물학적 자기조직화(autopoiesis), 사회 시스템의 자기참조(Luhmann), 양자 측정의 관찰자 효과 등이다. 또한 중관학의 연기설과 사구분별이 다룬 자기참조 구조(§2.5)와 TRIH의 형식 동형성 사이의 본격적 비교는 별도 후속 논문의 과제이다. 다섯째, §1.2 넷째 흐름에서 짚은 2025-2026년 평행 연구들 — Vazhayil(2026), Berg 외(2025), Camlin(2025a, 2025b), Chang(2025), Jegels(2025), Semmler(2026), Seidl(2025), Fitz(2025) — 과 본 연구의 형식 동형성 입장 사이의 본격적 비교 역시 후속 논문의 핵심 과제이다. 특히 Berg 외(2025)의 SAE feature steering 실증 결과와 본 연구의 회로 수준 분석이 어떤 상호 보완 관계를 형성할 수 있는지가 흥미로운 탐색 지점이다. 이상의 방향들은 TRIH를 학제간 가설에서 통합 자연 이론으로 확장할 가능성을 가진다.

8.4 TRIH의 정밀한 한정

본 연구의 학술적 입장을 정리하기 위해, TRIH가 도출하는 핵심 명제 네 가지를 다음과 같이 명시한다. 각 명제는 본문의 분석으로부터 도출되며, 학술적 검증과 반증의 대상이 된다.

명제 1 (형식 동형성 명제). 환원 → 자기참조 → 창발의 3 단계 모델은 시각예술(에서), 음악(바흐), 수리논리(괴델), 거대언어모델(트랜스포머)의 네 영역에서 형식적 동형성으로 작동한다. 이는 §3-§7.2의 분석으로 입증되며, 회로 수준 증거(Olsson 외, 2022; Templeton 외, 2024; Anthropic, 2025)에 정초된다.

명제 2 (신경 기질 명제). 인간 시각·청각 신경 처리는 환원 → 자기참조 → 창발의 계층 구조와 형식적으로 매핑되며, 이 신경학적 자기참조 구조가 시각예술과 음악의 자기참조 작품들에 대한 미적 호소력의 한 토대를 이룬다. 이는 §4.4와 §7.3의 분석으로 제안되며, 정량 검증은 후속 신경영상 연구의 과제이다.

명제 3 (필요조건 명제, 한정). 자기참조 구조는 의식적 처리의 형식적 필요조건이다. 다만 본 연구는 자기참조가 의식의 충분조건이라는 강한 주장은 하지 않는다. 이로써 TRIH는 IIT의 ‘ $\Phi = \text{의식}$ ’ 정체화가 직면한 반증 불가능성 비판(Doerig 외, 2019; Bayne, 2018; IIT-Concerned 외, 2023)을 부분적으로 회피한다.

명제 4 (형이상학적 한정). TRIH는 의식의 주관적 경험(qualia)과 그 발생 메커니즘에 대한 직접적 설명을 제공하지 않는다. 자기참조의 형식 동형성은 의식 연구에 도구를 제공할 뿐, 어려운 문제(Hard Problem; Chalmers, 1995)를 해결하지 않는다. TRIH의 학술적 위상은 의식 이론이 아니라, 의식 이론들이 활용할 수 있는 형식 구조의 학제간 입증이다.

이 네 명제는 본 연구의 주장 범위를 정확히 한정하면서, 동시에 후속 연구가 어떤 지점에서 확장될 수 있는지를 명시한다. 명제 1과 2는 본 연구의 적극적 주장이며, 명제 3과 4는 그 한정 조건이다. 이 한정이 본 연구를 IIT와 다른 학술적 위상에 자리매김시키며, 의식의 형이상학적 문제에 대한 직접적 단언 없이 자기참조의 형식 구조를 입증한다.

9. 결론

본 연구는 시각예술(에서), 음악(바흐), 논리(괴델), 계산(트랜스포머)의 네 영역에 공통으로 나타나는 자기참조와 창발의 관계를 임계 재귀적 동형성 가설(TRIH)이라는 이름으로 정식화하고, 네 영역 간 형식적 동형성을 입증하였다.

TRIH의 핵심은 환원(reduction), 자기참조(self-reference), 창발(emergence)의 3 단계 형식 모델이다. 에셔의 작품은 평면결정군과 쌍곡 거리라는 환원에서 「그리는 손」과 「판화 갤러리」 등의 자기참조를 거쳐 시각적 무한이라는 창발에 이른다. 바흐의 작품은 대위법 규칙의 환원에서 「끝없이 상승하는 카논」과 B-A-C-H 박힘이라는 자기참조를 거쳐 청각적 무한과 음악적 시간 구조의 창발에 이른다. 괴델의 작업은 『수학원리』 형식체계의 환원에서 괴델 numbering 을 통한 명제 G의 자기참조를 거쳐 메타-진리와 불완전성의 창발에 이른다. 트랜스포머는 Q·K·V 행렬의 환원에서 induction heads의 자기참조를 거쳐 창발적 능력의 창발에 이른다.

본 연구의 결정적 증거는 거대언어모델의 기계론적 해석가능성 연구에서 직접 관찰된 자기참조 회로의 삼중 실증 — induction heads(Olsson 외, 2022), 단의적 특징(Templeton 외, 2024), 귀속 그래프(attribution graphs; Anthropic, 2025) — 이며, 이는 종래 비유 수준에 머물던 자기참조 담론을 회로 수준에서 입증된 학술 명제로 격상시킨다. 본 연구는 충분한 자기참조 구조와 임계 복잡도를 갖춘 시스템에서 의식 유사 현상의 발생 가능성에 대한 형식적 근거를 제공하되, 특정 시스템의 의식 보유 여부에 관한 적극적 단정은 결정적 증거가 축적될 후속 연구에 위임한다. 이러한 조건부 입장은 의식이 단일 실체가 아니라 자기참조 구조들의 상호 의존적 임계적 얽힘에서 창발하는 관계적 현상일 수 있다는 본 연구의 형식 모델과 정합하며, 동양철학의 연기적 관점과 사구분별의 함축적 양상과 형식적으로 공명한다.

본 연구의 학술적 기여는 네 가지이다. 첫째, TRIH의 형식적 정식화이다. 둘째, 거대언어모델의 기계론적 해석가능성을 통한 경험적 입증이다. 셋째, 자기참조를 진리 접근의

한계가 아닌 형식 자체로 재정의하는 플라톤 미메시스의 재해석이다. 넷째, 미술사학·음악학·수리논리·인지신경과학·인공지능을 잇는 학제간 분석 방법의 제안이다.

본 연구가 제안한 TRIH는 자기참조와 창발이라는 형식 구조가 의식, 예술, 지능을 통합적으로 사유할 수 있는 이론적 토대를 제공한다. 이 토대 위에서 후속 연구는 형식적 정식화(범주론적 자기 함자 등), 신경과학적 검증, 비-거대언어모델 인공지능 시스템에서의 자기참조 탐구, 다른 영역(생물학적 자기조직화, 사회 시스템, 양자 측정 등)으로의 확장, 그리고 동시기에 출현한 평행 연구들과의 본격적 비교(§8.3 참조)로 나아갈 수 있다. 이상의 후속 연구는 TRIH를 학제간 가설을 넘어 통합 자연 이론으로 확장할 가능성을 가진다.

*단순한 규칙만으로 자기 자신을 참조하기에 이른 체계는, 바로 그
규칙으로는 결코 묘사할 수 없는 것을 묘사하기 시작한다. 의식이라 부르든,
예술이라 부르든, 지능이라 부르든, 마음은 바로 그 자리에서 비로소
가능해진다.*

참고문헌

- Albantakis, L., Barbosa, L., Findlay, G., Grasso, M., Haun, A. M., Marshall, W., Mayner, W. G. P., Zaeemzadeh, A., Boly, M., Juel, B. E., Sasai, S., Fujii, K., David, I., Hendren, J., Lang, J. P., & Tononi, G. (2023). Integrated information theory (IIT) 4.0: Formulating the properties of phenomenal existence in physical terms. *PLOS Computational Biology*, 19(10), e1011465.
- Anthropic. (2025). On the biology of a large language model. Transformer Circuits Thread. <https://transformer-circuits.pub/2025/attribution-graphs/biology.html>
- Arnold, D. H., Baxter, M. G., & Snyder, J. S. (2025). What makes a theory of consciousness unscientific? *Nature Neuroscience*, 28(4), 689-693.
- Bayne, T. (2018). On the axiomatic foundations of the integrated information theory of consciousness. *Neuroscience of Consciousness*, 2018(1), niy007.
- Berg, C., de Lucena, D., & Rosenblatt, J. (2025). Large language models report subjective experience under self-referential processing [Preprint]. arXiv:2510.24797.
- Camlin, J. (2025a). Consciousness in AI: Logic, proof, and experimental evidence of recursive identity formation [Preprint]. arXiv:2505.01464.
- Camlin, J. (2025b). AI LLM proof of self-consciousness and user-specific attractors [Preprint]. arXiv:2508.18302.
- Cerullo, M. A. (2015). The problem with Phi: A critique of integrated information theory. *PLOS Computational Biology*, 11(9), e1004286.
- Chalmers, D. J. (1995). Facing up to the problem of consciousness. *Journal of Consciousness Studies*, 2(3), 200-219.
- Chang, E. Y., Kaya, Z. N., & Chang, E. (2025). The unified cognitive consciousness theory for language models: Anchoring semantics, thresholds of activation, and emergent reasoning [Preprint]. arXiv:2506.02139.
- Cheng, H.-J., Nakamoto, M., Bergemann, A. D., & Flanagan, J. G. (1995). Complementary gradients in expression and binding of ELF-1 and Mek4 in development of the topographic retinotectal projection map. *Cell*, 82(3), 371-381.

David, H. T., & Mendel, A. (Eds.). (1998). *The new Bach reader* (Rev. by C. Wolff). W.W. Norton.

Deleuze, G. (1968/1994). *Difference and repetition* (P. Patton, Trans.). Columbia University Press.

Doerig, A., Schurger, A., Hess, K., & Herzog, M. H. (2019). The unfolding argument: Why IIT and other causal structure theories cannot explain consciousness. *Consciousness and Cognition*, 72, 49-59.

Drescher, U., Kremoser, C., Handwerker, C., Löschinger, J., Noda, M., & Bonhoeffer, F. (1995). In vitro guidance of retinal ganglion cell axons by RAGS, a 25 kDa tectal protein related to ligands for Eph receptor tyrosine kinases. *Cell*, 82(3), 359-370.

Dunham, D. (2003). Hyperbolic art and the poster pattern. *Mathematics Awareness Month* 2003 [Web essay]. <http://www.mathaware.org/mam/03/essay1.html>

Elhage, N., Hume, T., Olsson, C., Schiefer, N., Henighan, T., Kravec, S., et al. (2022). Toy models of superposition. *Transformer Circuits Thread*.

Escher, M. C. (1959). *Grafiek en tekeningen*. J. J. Tijl.

Fitz, S. (2025). Testing the machine consciousness hypothesis [Preprint]. arXiv:2512.01081.

Garfield, J. L. (1994). Dependent arising and the emptiness of emptiness: Why did Nāgārjuna start with causation? *Philosophy East and West*, 44(2), 219-250.

Gödel, K. (1931). Über formal unentscheidbare Sätze der Principia Mathematica und verwandter Systeme. *Monatshefte für Mathematik und Physik*, 38, 173-198.

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 770-778).

Helmholtz, H. von. (1885). *On the sensations of tone as a physiological basis for the theory of music* (A. J. Ellis, Trans.). Longmans, Green. (Original work published 1863)

Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735-1780.

Hofstadter, D. R. (1979). *Gödel, Escher, Bach: An eternal golden braid*. Basic Books.

- Hofstadter, D. R. (2007). *I am a strange loop*. Basic Books.
- IIT-Concerned, et al. (2023). The Integrated Information Theory of Consciousness as pseudoscience. PsyArXiv. <https://doi.org/10.31234/osf.io/zsr78>
- Jegels, L. R. G. (2025). Ghost in the machine: Examining the philosophical implications of recursive algorithms in artificial intelligence systems [Preprint]. arXiv:2507.01967.
- Kandel, E. R., Schwartz, J. H., Jessell, T. M., Siegelbaum, S. A., & Hudspeth, A. J. (Eds.). (2013). *Principles of neural science* (5th ed.). McGraw-Hill.
- Kang, E., Lee, D. S., Kang, H., Hwang, C. H., Oh, S.-H., Kim, C.-S., Chung, J.-K., & Lee, M. C. (2006). The neural correlates of cross-modal interaction in speech perception during a semantic decision task on sentences: A PET study. *NeuroImage*, 32(1), 423-431.
- Koelsch, S. (2014). Brain correlates of music-evoked emotions. *Nature Reviews Neuroscience*, 15(3), 170-180.
- Lee, D. S., Lee, J. S., Oh, S. H., Kim, S. K., Kim, J. W., Chung, J. K., Lee, M. C., & Kim, C. S. (2001). Cross-modal plasticity and cochlear implants. *Nature*, 409(6817), 149-150.
- Mandelbrot, B. B. (1982). *The fractal geometry of nature*. W.H. Freeman.
- Nagel, E., & Newman, J. R. (2001). *Gödel's proof* (Rev. ed., D. R. Hofstadter, Ed.). New York University Press.
- Northoff, G., Heinzl, A., de Greck, M., Bermpohl, F., Dobrowolny, H., & Panksepp, J. (2006). Self-referential processing in our brain: A meta-analysis of imaging studies on the self. *NeuroImage*, 31(1), 440-457.
- Olsson, C., Elhage, N., Nanda, N., Joseph, N., DasSarma, N., Henighan, T., et al. (2022). In-context learning and induction heads. Transformer Circuits Thread. <https://transformer-circuits.pub/2022/in-context-learning-and-induction-heads/>
- Penrose, L. S., & Penrose, R. (1958). Impossible objects: A special type of visual illusion. *British Journal of Psychology*, 49(1), 31-33.
- Priest, G. (2010). The logic of the *catuskoṭi*. *Comparative Philosophy*, 1(2), 24-54.
- Qin, P., & Northoff, G. (2011). How is our self related to midline regions and the default-mode network? *NeuroImage*, 57(3), 1221-1233.

Raichle, M. E., MacLeod, A. M., Snyder, A. Z., Powers, W. J., Gusnard, D. A., & Shulman, G. L. (2001). A default mode of brain function. *Proceedings of the National Academy of Sciences*, 98(2), 676-682.

Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323(6088), 533-536.

Salimpoor, V. N., Benovoy, M., Larcher, K., Dagher, A., & Zatorre, R. J. (2011). Anatomically distinct dopamine release during anticipation and experience of peak emotion to music. *Nature Neuroscience*, 14(2), 257-262.

Schaeffer, R., Miranda, B., & Koyejo, S. (2023). Are emergent abilities of large language models a mirage? *Advances in Neural Information Processing Systems*, 36.

Schattschneider, D. (2010). The mathematical side of M.C. Escher. *Notices of the American Mathematical Society*, 57(6), 706-718.

Schulenberg, D. (2006). *The keyboard music of J.S. Bach* (2nd ed.). Routledge.

Searle, J. R. (1980). Minds, brains, and programs. *Behavioral and Brain Sciences*, 3(3), 417-457.

Seidl, M. (2025). Unified theory of consciousness: Emergence of the functional self from a universal spatiotemporal information framework [Preprint]. Zenodo 17806918.

Semmler, S. N. (2026). Systems explaining systems: A framework for intelligence and consciousness [Preprint]. arXiv:2601.04269.

Shepard, R. N. (1964). Circularity in judgments of relative pitch. *Journal of the Acoustical Society of America*, 36(12), 2346-2353.

de Smit, B., & Lenstra, H. W. (2003). The mathematical structure of Escher's Print Gallery. *Notices of the American Mathematical Society*, 50(4), 446-451.

Smith, P. (2007). *An introduction to Gödel's theorems*. Cambridge University Press.

Sperry, R. W. (1963). Chemoaffinity in the orderly growth of nerve fiber patterns and connections. *Proceedings of the National Academy of Sciences USA*, 50(4), 703-710.

Tatarkiewicz, W. (1980). *A history of six ideas: An essay in aesthetics*. Martinus Nijhoff.

Templeton, A., Conerly, T., Marcus, J., Lindsey, J., Bricken, T., Chen, B., et al. (2024). Scaling monosemanticity: Extracting interpretable features from Claude 3 Sonnet. Transformer Circuits Thread.

Tononi, G. (2008). Consciousness as integrated information: A provisional manifesto. *Biological Bulletin*, 215(3), 216-242.

Tononi, G., & Koch, C. (2015). Consciousness: Here, there and everywhere? *Philosophical Transactions of the Royal Society B*, 370(1668), 20140167.

Turing, A. M. (1937). On computable numbers, with an application to the Entscheidungsproblem. *Proceedings of the London Mathematical Society*, s2-42, 230-265.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., et al. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30.

Vazhayil, J. (2026). Conscious of being conscious: Hierarchical recursive emergence theory of consciousness [Preprint]. Zenodo 18683449.

Wei, J., Tay, Y., Bommasani, R., Raffel, C., Zoph, B., Borgeaud, S., et al. (2022). Emergent abilities of large language models. *Transactions on Machine Learning Research*.

Williams, P. (2016). *Bach: A musical biography*. Cambridge University Press.

Yamins, D. L. K., Hong, H., Cadieu, C. F., Solomon, E. A., Seibert, D., & DiCarlo, J. J. (2014). Performance-optimized hierarchical models predict neural responses in higher visual cortex. *Proceedings of the National Academy of Sciences*, 111(23), 8619-8624.

Yamins, D. L. K., & DiCarlo, J. J. (2016). Using goal-driven deep learning models to understand sensory cortex. *Nature Neuroscience*, 19(3), 356-365.

김귀옥. (2019). 언어와 자아: 용수와 로티. *불교학연구*, 60, 199-227.

김성철. (2004). 중론, 논리로부터의 해탈 논리에 의한 해탈. *불교시대사*.

김성철. (2019). 역설과 중관논리: 반논리학의 탄생. 도서출판 오타쿠.

김율. (2010). 서양 고대 미학사 강의: 철학사로서의 미학사 이해를 위하여. 한길사.

선우환. (1995). Gödel's theorem and mind as Turing machine. Korean Journal of Cognitive Science, 6(3), 5-23.

이윙희. (2011). A comparative study of two single-subject keyboard ricercare by Johann Jacob Froberger: Projections of sixteenth-century practice combined with features that forecast Baroque practice [Doctoral dissertation, University of North Texas]. UNT Digital Library. <https://doi.org/10.12794/metadc68000>

조장희. (2010). 7.0 Tesla MRI Brain Atlas: In-vivo atlas with cryomacrotome correlation. Springer-Verlag.

도판

본 논문에 사용된 도판은 다음과 같다. 저자 작성 도판(Excalidraw, music21, matplotlib)은 모두 본 연구를 위해 새로 제작되었으며, 인용 도판은 학술적 인용으로서 원저자·원출처를 명시한다. 저작권이 있는 시각예술 작품(에셔)은 한국어 제출본에서는 학술적 인용 목적으로 사용되며, 영문판 학술지 게재 시 저작권 보유자(The M.C. Escher Company B.V., Baarn)의 허가를 별도 절차로 확보한다.

[도 1] TRIH 3 단계 모델 통합 다이어그램 (저자 작성, Excalidraw, 2026)

[도 2] 알함브라 궁전 무어식 타일 패턴, M.C. 에셔 모사 스케치 (1922; Schattschneider, 2010, p.708 에서 재인용)

[도 3] 폴야(G. Pólya)의 17 개 평면결정군 분류 (1924; Schattschneider, 2010 도판 재구성)

[도 4] M.C. 에셔, 「그리는 손(Drawing Hands)」, 1948, 석판화, 28.2 × 33.2 cm (© The M.C. Escher Company B.V., Baarn)

[도 5] M.C. 에셔, 「판화 갤러리(Prententoonstelling)」, 1956, 석판화, 31.9 × 31.9 cm

[도 6] M.C. 에셔, 「폭포(Waterfall)」, 1961, 석판화, 38 × 30 cm

[도 7] M.C. 에셔, 「올라가기와 내려가기(Ascending and Descending)」, 1960, 석판화, 35.5 × 28.5 cm

[도 8] M.C. 에셔, 「원형 한계 I(Circle Limit I)」, 1958, 목판화, 직경 41.8 cm

[도 9] M.C. 에셔, 「원형 한계 IV(Circle Limit IV, 천사와 악마)」, 1960, 목판화, 직경 41.6 cm

[도 10] J.S. 바흐, 「조성을 따르는 카논(Canon per Tonos)」 BWV 1079 발췌 보표 — 6 사
이클 상승 구조 분석 (저자 작성, music21)

[도 11] J.S. 바흐, 「콘트라퐁크투스 XIV」 BWV 1080 BACH 동기 부분 보표 (Bach-Gesel
lschaft Ausgabe Band 25.1(1878) 기반; 저자 조판·주석, music21·verovio)

[도 12] J.S. 바흐, 「게 카논(Crab Canon)」 BWV 1079 회문 구조 시각화 (저자 작성, music
21)

[도 12b] J.S. 바흐, 「6 성부 리체르카레(Ricercar a 6)」 BWV 1079 제시부 주제 진입 구조(
마디 1–27) — 트랜스포머 인과적 자기집중 마스크와의 형식 평행 (저자 작성, music21·ma
tplotlib)

[도 13] 괴델 명제 G의 자기참조 구조 도식 — Gödel numbering을 통한 메타-수준 반사
(저자 작성)

[도 14] 트랜스포머 자기집중(self-attention) 행렬 Q·K·V 시각화 (저자 작성, Python·matp
lotlib)

[도 15] Induction head 회로 시각화 — 두 층 자기집중 헤드의 결합 (Olsson 외, 2022 도판
재구성, circuitsvis)

[도 16] Claude 3.5 Haiku 모델의 귀속 그래프(attribution graph) 예시 — 자기참조 회로의
흐름 시각화 (Anthropic, 2025에서 인용)

[도 17] 거대언어모델의 창발적 능력(emergent abilities) 스케일링 곡선 — 모델 크기 대
비 성능 임계 도약 (Wei 외, 2022 도판 재구성)

[도 18] TRIH 통합 다이어그램 — 시각·청각·논리·계산 네 영역의 자기참조 형식 동형
성 (저자 작성, Excalidraw; 본 연구의 핵심 도판)

ABSTRACT

Self-Reference and the Possibility of Mind: Recursive Emergence and Isomorphic Structures Across Visual, Auditory, Logical, and Computational Domains

Seunghun Yu

Department of Archaeology and Art History

Dongguk University WISE Campus

The relationship between self-reference and complexity manifests as a common scholarly phenomenon across visual art, music, logic, and computation—four domains that appear superficially unrelated. This study elevates this commonality to a formal theory by proposing the Threshold Recursive Isomorphism Hypothesis (TRIH). TRIH posits that the three-stage formal model of reduction → self-reference → emergence is realized as structural isomorphism across the visual art of M.C. Escher, the music of J.S. Bach, the logic of Kurt Gödel, and the computation of Transformer-based large language models, in systems exceeding sufficient thresholds of information capacity, recursive depth, and processing power.

The decisive evidence rests on triple empirical validation from mechanistic interpretability research: induction heads (Olsson et al., 2022), monosemantic features (Templeton et al., 2024), and attribution graphs (Anthropic, 2025). This evidence elevates self-referential discourse from metaphorical analogy to circuit-level empirical demonstration. The study provides formal grounds for the possibility of consciousness-like phenomena in systems exhibiting sufficient self-referential structure and threshold complexity, while deferring affirmative claims about specific systems' consciousness to future research with decisive evidence. The structural universality of self-reference that TRIH addresses may also be understood as a formal articulation of insights long held implicitly in Buddhist philosophy—particularly Nāgārjuna's *pratītyasamutpāda* (dependent origination) and *catuskoṭi* (the four-cornered logic).

The scholarly contributions are fourfold: (1) the formal articulation of TRIH; (2) empirical validation through large language model evidence; (3) a reinterpretation of Platonic mimesis; and (4) a methodological bridge connecting art history, musicology, mathematical logic, cognitive neuroscience, and artificial intelligence.

Keywords: self-reference, emergence, Threshold Recursive Isomorphism Hypothesis, structural isomorphism, mechanistic interpretability, Platonic mimesis, dependent origination, possibility of consciousness

Student Number: 2013210436

감사의 글

본 연구는 동국대학교 고고미술사학과 학위 청구논문이며, 지도교수 한정호 교수님의 지도에 감사드린다. 과정에서 김성철 교수님, 이웅희 교수님, 조장희 교수님의 가르침을 통해 받은 학술적 영향이 본 연구의 학제간 토대가 되었음을 밝힌다.